BioExplainR 面向 iMeta / 一区期刊的继续改造与投稿路线图

基于完整 R 包源码、测试、研究脚本、用户指南与当前论文交付的系统审查

软件版本	BioExplainR 0.3.1
审查日期	2026-10-05
主要目标	iMeta；备选为当前投稿年度核验后的一区计算生物学/生物信息学期刊
当前结论	软件完成度高，论文证据仍不足以支撑 iMeta 的强主张
路线原则	停止以增加函数数量为主，改为独立多组学、claim-level 评价和真实任务证据

关于“80% 几率”的边界

任何人都不能根据软件审查保证某个期刊的录用概率。本路线把 80% 定义为内部“可投稿准备度”：在没有 P0 阻断项、完成独立评价、公开复现和伦理/作者信息核验后，团队有足够证据把稿件投向 iMeta 或一个匹配的一区备选。它不是录用承诺，也不是编辑决策的统计预测。

执行摘要

BioExplainR 已经不是一个简单的 LLM wrapper。它有统一的 bio_context 中间表示、差异表达/富集/单细胞/PCA/图形/ExpressionSet 适配器、离线解释、可选模型调用、证据对象、声明验证、图形交叉核对、错误诊断、显式修复不变量、项目依赖图、报告和 Shiny 工作台。测试和包检查也已达到可以作为软件方法学论文基础的水平。

当前论文的核心证据主要证明了三件事：R 适配器可以从完整输入计算确定性 facts；受限模型协议可以把已经提供的 facts 复制到结构化 claims；受控错误注入能够被声明/图形/不变量检查器识别。这些是重要的工程和机制结果，但不是模型自由文本质量、证据支持质量、多组学整合收益或真实用户收益的证明。

要提高 iMeta 或其他一区期刊的竞争力，论文必须改成一个更窄、更强的科学主张：BioExplainR 是否能降低组学解释中的可检测统计错误、无支持生物学表述和证据错配，并在真实的整合组学工作流中留下可复核的证据链。

最重要的决策

不要继续优先增加教育题目、更多连接预设或更多简单表格适配器。下一轮开发资源应优先投入：1）typed claim ledger；2）空间转录组与结构层证据链；3）MultiAssayExperiment/SpatialExperiment 真实案例；4）冻结后的独立 claim-level benchmark；5）正规专家/用户任务研究；6）公开仓库、DOI、容器和 CI。

一、审查范围与当前包画像

本路线基于项目中可见的 R 包源码、NAMESPACE、DESCRIPTION、man/*.Rd、testthat 测试、inst/examples、架构/需求/评测/安装/工作台文档、研究脚本、当前 PAPER_DRAFT 与 SUPPLEMENTARY_MATERIAL，以及已经生成的用户指南和投稿审计文件。未把历史交接文件中的过期数字当作当前状态；以 2026-10-05 交接说明和当前文件内容为准。

审查对象	当前状态	对投稿的意义
公开导出 API	74 个函数；另有 S3 print/as.list/format 方法	功能面很完整，但论文不能按函数数量证明科学创新
核心中间表示	bio_context：facts、top_features、plot_mapping、provenance、uncertainty、metadata	是最值得形成论文中心贡献的数据契约
对象覆盖	DE、富集、Seurat、SCE、SE、ExpressionSet、PCA、ggplot、细胞组成、generic	覆盖转录组和单细胞；尚未形成 iMeta 所需的跨模态主案例
模型接口	OpenAI-compatible、Anthropic、DeepSeek、Ollama、自定义预设	协议层成熟；不等于模型质量已经被证明
验证层	显式 claims、证据 ID、图形映射、修复不变量	机制贡献明确；自由文本和证据支持仍未完整评价
运行记录	警告、错误栈、对象摘要、包调用、版本和报告	有利于可复现和审计；尚未形成公开 artifact 标准
浏览器工作台	Shiny 本地运行，连接间工作区隔离	适合工作流展示；不是安全多租户服务
软件验证	525 项检查，524 通过、1 跳过；R CMD check OK	软件质量基础强，但不是外部方法效果证据
模型规模实验	120 个程序生成案例、480 facts、三种输入、三轮重复	主要是事实传递/序列化压力测试，不能作为自然数据泛化

审查对象	当前状态	对投稿的意义
人类评价	3 位评分者和 30 位功能评分的聚合材料	当前缺少招募、伦理、同意、任务正确率、对照和原始评分审计

1.1 当前功能模块审计

模块	已实现功能	当前证据	投稿定位
配置与 LLM	bio_config、预设、端点、重试、OpenAI/Anthropic、脱敏	mock 协议测试；少量真实调用	基础设施，不是主要创新
对象适配	DESeq2/limma/edgeR、ORA/GSEA、Seurat/SCE/SE/ExpressionSet、PCA、ggplot	真实 airway、PBMC3k、pasilla、ALL、bladderbatch	核心方法；需要跨模态扩展
解释	R facts + 本地模板 + 可选模型分节解释	离线测试和结构化模型实验	中心工作流，但要用语义质量评价支撑
证据	用户证据、Europe PMC、GO、Reactome、KEGG、UniProt、缓存	mock 端点和少量实端点	需要从可追溯 ID 升级为支持关系评价
验证	claim values/directions/path/citation、图形 cross-check、fix invariants	90 项声明挑战、9 项图形挑战、修复挑战	最有辨识度的技术贡献
诊断	错误分类、栈、离线建议、可选模型建议	规则单元测试	需要真实错误 benchmark 才能成为结果
项目	依赖图、派生证据提示、跨结果一致性	循环/未知依赖和示例	适合承载多组学关系
绘图与 Shiny	PCA、UMAP、富集、热图和本地工作台	浏览器 smoke test	展示层；不能作为主要科学贡献
教学评估	题库、随机、专家 rubric、学习分析	软件测试；没有正式学习实验	应从主论文主线降为扩展或后续研究

二、现阶段能发什么，为什么还不能直接冲 iMeta

以当前软件和论文，最稳妥的描述是“高完成度、可复现的软件方法学工作，具有机制验证，但缺少独立的科学效果证据”。它已经明显超过只有 demo 和一个模型调用的软件短文，但还没有证明 BioExplainR 在真实组学研究中带来可量化的错误降低、时间收益、证据质量提高或跨模态整合价值。

维度	当前判断	主要原因
软件工程	强	模块化、可选依赖、脱敏、mock、R CMD check、浏览器检查和用户指南完整
可复现性	强但未闭环	有结果和哈希，但公开仓库、DOI、固定环境和 CI 仍需正式发布
统计边界意识	强	raw p/padj、pseudoreplication、ORA/NES、batch 和因果边界写得清楚
方法创新	中上	事实契约、claim validation、plot cross-check、fix invariants 的组合有特色
模型能力证据	弱到中	facts_only 的 100% 是事实传递，不是模型独立推理；自由文本错误已被负例证明
生物学价值	中等偏弱	目前以对象接入和解释工作流为主，缺少真实多组学科学问题
人类收益	不足	当前功能评分不是正式用户实验；伦理和任务终点不完整
iMeta 适配	当前中等；空间/结构案例完成后可强	iMeta 需要整合组学/生物学应用主线，当前 package 主线仍偏 R 解释层

投稿判断

当前不建议把稿件包装成“LLM 生物信息学准确率达到 100%”。如果现在投稿，审稿人最可能指出：目标事实已由 R 计算并写入输入、案例是程序生成且与开发流程相关、证据只检查引用闭集、自由文本存在 shrinkage 语义错误、外部评分不是正式用户研究。

2.1 iMeta 的正确切入角度

iMeta 目标应当不是“我有一个功能很多的 R 包”，而是“整合组学结果的解释容易发生事实、统计和证据错配；BioExplainR 用一个可审计的数据契约和 claim ledger 把这些风险分开，并在跨模态案例中验证风险是否下降”。

- 主科学问题：在空间转录组与其他组学/结构层信息的联合解释中，确定性 facts、空间关系、证据关系和显式验证能否降低 LLM 的可检测错误?
- 主技术贡献：将不同 R 对象和模态统一为带来源状态、样本对齐、设计信息、事实路径和不确定性的 context；将模型文本拆成可核对的 typed claims。
- 主应用贡献：在一个真实空间组学案例上展示从 spot/区域接入、空间统计、候选靶点筛选、结构计算结果、证据追踪到报告输出的完整链条。
- 必须明确的边界：不声称发现新的生物学机制，不声称模型具有普遍推理能力，不声称本地 callr 进程是安全沙箱，不声称引用 ID 证明了文章支持关系。

三、阻断项清单：P0 必须解决，P1 强烈建议，P2 可延后

等级	阻断项	现有证据/代码位置	通过标准
P0	缺少真正独立的自由文本/生物学 claim benchmark	bio_validate_explanation 只核对显式 value/direction/path/citation；当前规模实验把 facts 直接传给模型	冻结外部 test set；至少 100 个专家标注 claims；报告 unsupported、statistical、biological、citation 指标和 CI
P0	缺少 iMeta 风格空间/跨模态真实案例	当前 adapter 以 bulk RNA、单细胞、表达对象和结果表为主；没有 SpatialExperiment 或结构层主流程	至少一个真实 SpatialExperiment/Seurat spatial 案例；空间统计、区域/样本关系、结构层候选和证据链全部可复现
P0	当前 100% 结果容易被解释为答案泄漏/事实复制	research/run_main_scale_experiment.R:41-46, 200-231；目标 facts 来自 BioExplainR context 并写入 prompt	将 transport fidelity 与 scientific interpretation 分为两个 endpoint；后者不把答案直接作为待复制 claim 输入
P0	证据只验证 ID 闭集，不验证支持关系	R/explanation-validation.R:116-121；evidence-live 主要产生检索记录和定义	建立支持/矛盾/无关/定义-only 标注；专家盲评 evidence-to-claim support precision/recall
P0	人类评价不能作为当前正式用户研究结果	docs/PAPER_DRAFT.md:102-106；SUPPLEMENTARY S5 明确缺招募、伦理、同意、补偿和任务终点	取得真实伦理审批/豁免和同意记录；预注册；随机对照或至少专家盲评的任务正确率和时间
P0	当前文档和审计仍有历史状态混杂	README.md 仍保留 6 案例/54 请求；research/audit_results.R 仍核对旧 fact_scores.csv 225 行/54 调用	所有 README、audit、manifest、论文、补充材料只引用一个冻结版本；旧结果移动到明确 historical 目录
P1	默认 JSON 序列化精度没有形成正式契约	R/utils.R:.json 使用 digits=10；规模脚本另行使用 digits=17	内部 facts JSON 默认保留 17 位或显式 precision；精度回归测试覆盖 PCA、极小 p 和零值
P1	typed claim schema 不够严格	当前 claims 主要检查 fact/value/direction/evidence；自由 prose	加入 claim_type、fact_path、value、unit、

等级	阻断项	现有证据/代码位置	通过标准
		仍未结构化	direction、evidence_role、scope、status，拒绝未知字段或保留 unverified
P1	大对象隐私保护是约定，不是全面审计	R/utils.R:.object_summary、bio_context_payload；top feature/metadata 仍可能含用户自定义标识	敏感字段注入测试、payload allowlist、manifest 记录发送字段和 hash，明确脱敏边界
P1	修复执行不是 OS sandbox	R/validate.R:163-167；Shiny 同样共享文件/网络权限	论文删除安全沙箱暗示；研究代理使用 Docker/Apptainer/no-network/no-write baseline，并单独审计
P1	错误诊断和图形核对缺少自然案例评价	当前主要是规则测试和人工注入 challenge	真实或盲法构造的错误/图形集，报告 top-1/top-3、false-pass 和 not-checkable coverage
P2	教学和 Shiny 功能分散主线	teaching.R、evaluation.R、shiny-app.R 功能齐全但不是同一科学终点	主论文降为扩展模块；教学效果另文或补充研究，不用功能评分支撑主结论

四、必须先做的软件改造

下列改造是为了让 BioExplainR 能够被严格评价，而不是为了堆功能。每项都需要代码、测试、文档和研究记录同时更新。

4.1 建立 typed claim ledger

当前验证器能判断“某个声明的数字是否等于某个 fact”，但不能系统区分统计事实、统计解释、生物学关联、因果断言和证据支持。建议把 claims 从任意模型返回的 list 升级为固定 schema，并让报告显示每个 claim 的状态和检查范围。

字段	必须含义	示例	验证方式
id	稳定的 claim 标识	claim_001	唯一且可追踪
claim_type	事实、统计解释、关联、因果、证据支持、设计、图形映射	statistical_fact	枚举值；未知类型为 unverified
text	模型或模板生成的文字	999 features pass threshold	不自动视为正确
fact_path	指向 context facts 的路径	facts.n_significant	路径存在且值类型可比较
value/unit	标量值和单位	999 / features	数字容差、字符串和单位检查
direction	仅在有符号效应时使用	up	和事实符号或预设方向比较
scope	样本、模态、比较和阈值范围	airway; trt vs untrt	与 metadata/provenance 对齐
evidence	证据 ID 和证据角色	supports / definition_only	闭集 + 专家支持关系
status	pass/fail/partial/unverified/not_assessable	partial	验证器填充，模型不能自行声明 pass

```
# 建议新增的公开接口方向（名称可调整）
bio_claim_ledger(explanation)
bio_validate_claims(explanation, policy = bio_claim_policy())
bio_evidence_support(claim, evidence, annotation = c("supports", "contradicts", "definition_only",
"irrelevant"))
bio_context_manifest(ctx, include_hashes = TRUE)
```

最低实现要求：模型输出中没有 fact_path 的自由文本必须显式标为 unverified；causal claim 默认不允许自动 pass；definition_only 证据不能满足 experiment_support；claim scope 必须和物种、组织、比较方向、模态一致。

4.2 增加跨模态对象契约

iMeta 的最小软件增量不是再支持一种结果表，而是能够处理“同一组样本的多个模态”。建议优先支持 SpatialExperiment、Seurat 的空间对象/图像和 MultiAssayExperiment，并把各模态 context 接入现有 bio_project。空间转录组应成为主入口，结构计算作为经过 provenance 和验证的外部证据层。

能力	最小实现	不能省略的检查
模态注册	transcriptome、methylation/CNV、proteome、metabolome、microbiome 至少两个	每个模态的 class、source package、analysis type、feature unit
样本对齐	统一 sample map 和交集/缺失表	重复 sample ID、模态缺失、样本顺序、配对关系
设计信息	group、batch、donor、timepoint、paired unit	生物学重复不是 feature/cell；组别和 batch 可识别性
结果依赖	模态内和模态间依赖边	派生结果不当作独立验证；同一输入的证据相关性
跨模态结论	agreement、discordance、modality-specific	方向一致不等于因果；缺失模态不能被模型补全
报告	每模态 facts + joint checks + claim ledger	所有结论能回到对象、路径和证据

推荐的第一套真实案例：一个有匹配样本的转录组 + DNA 甲基化/CNV 或转录组 + 蛋白组数据集；如果能找到样本级匹配的微生物组 + 代谢组 + 转录组数据，iMeta 相关性更强。数据集必须在开发前冻结，记录下载 URL、版本、SHA-256、样本交集和所有排除规则。不要为了“多组学”把不匹配的公开数据拼在一起。

4.3 空间转录组与分子对接：可以结合，但必须分层

空间转录组和分子对接确实是当前很有吸引力的研究热点，但二者回答的是不同问题：空间转录组回答“哪些分子信号在什么组织位置、哪些细胞/区域共同出现”；分子对接回答“给定受体结构、配体结构和参数时，某种结合构象在计算上是否可行”。空间共定位加上较好的 docking score 不能直接证明真实结合、通路激活、药效或因果机制。

推荐论文定位

Spatially resolved and structure-aware evidence-constrained interpretation of omics results。空间层负责定位和组织上下文，结构层负责候选相互作用的计算可行性，文献/数据库负责知识背景；BioExplainR 负责把每层事实、限制和验证状态连接起来。

层级	建议支持	必须计算的 facts	不能自动推出
空间对象	SpatialExperiment、Seurat spatial assay/image、空间 metadata	spot/cell 数、切片/样本、坐标范围、组织覆盖、QC、区域/cluster、邻域图	坐标接近不等于细胞互作或谱系关系
空间统计	已有空间变异基因、空间 DE、邻域/共定位、Moran's I/Geary's C 等结果	统计方法、空间邻接定义、显著特征、效应方向、样本/切片分母	单切片显著不等于跨患者可重复
候选分子	ligand/receptor、靶点、药物或代谢物候选表	ID 类型、物种、区域表达、共表达、来源、筛选规则	表达共现不等于物理结合
结构计算	AutoDock Vina/smina/GNINA 或 HADDOCK 等外部结果解析	引擎版本、结构 ID、预处理、搜索空间、score 分布、pose cluster、RMSD、接触残基、对照/decoy	docking score 不等于实验结合自由能或药效
证据图	空间 claim → 结构 claim → 文献/数据库 claim 的依赖图	每条 claim 的类型、scope、evidence role、验证状态	多层证据一致不自动证明机制

优先级建议：第一阶段先做 SpatialExperiment/Seurat spatial 的对象与结果适配；第二阶段接收外部 docking 输出和 provenance，不在 R 包内部手写 docking 引擎；第三阶段做空间-结构 claim graph 和独立专家 benchmark。这样可以利用热点，但不会把一个不可验证的结构模型变成软件的未经审查结论。

4.3.1 空间转录组软件接口

- 新增 SpatialExperiment adapter：读取 spatialCoords、imgData、colData、assayNames、区域/cluster、sample/section/donor 信息；默认不向模型发送完整坐标、图像或 barcode。
- 支持已有结果表：空间变异基因、空间 DE、区域 marker、邻域富集、ligand-receptor 候选和 deconvolution 输出；记录方法、空间邻接定义和统计分母。
- 新增空间 facts：每个 section 的 spot/cell 数、坐标范围、组织覆盖率、缺失坐标、每个样本/区域的观察数、空间统计阈值和多重检验方法。
- 新增 spatial cross-check：检查 spot/region ID 对齐、坐标和 metadata 对齐、图形映射、区域子集和结果表来源；复杂空间图形无法核查时返回 not_checkable。
- 所有空间生物学 claim 都要带 scope：sample/section、region、cell type、species、assay 和 comparison；没有 scope 的 claim 不自动通过。

```
# 建议接口方向；具体名称可以在 API 设计评审后确定
bio_spatial_context(x, sample_col = NULL, section_col = NULL, region_col = NULL)
bio_spatial_neighbors(x, method = c("stored", "knn", "radius"))
bio_spatial_cross_check(plot, source, allow_subset = FALSE)
bio_docking_context(result, receptor = NULL, ligand = NULL, provenance = list())
bio_integrate_spatial_structure(spatial_ctx, docking_ctx, evidence = NULL)
```

4.3.2 分子对接不能只写成一个 score

- 区分小分子-蛋白对接和蛋白-蛋白对接；二者的输入、搜索空间、评分和验证方式不同。
- R 包负责读取和审计外部引擎输出，不负责在模型生成代码的情况下自动执行 docking。外部程序、容器、命令、结构文件 hash 和参数必须进入 provenance。
- 保存 top pose、score 分布、聚类大小、RMSD、界面残基、氢键/疏水接触和 decoy/negative-control 结果；只有一个最佳 score 不足以形成 claim。
- 明确 docking score 的尺度和引擎版本，不能跨引擎直接排序；不要把 score 直接写成 binding affinity 或 ΔG。
- 候选选择必须在 docking 前冻结，或使用独立的候选发现集和 test 集；否则空间表达高、文献强和 docking 好的候选会产生严重选择偏倚。
- 结构缺失、低分辨率、配体质子化、柔性、口袋定义和蛋白构象都会影响结果，均应进入 uncertainty。

4.3.3 空间 + docking 的主案例设计

一个合格的主案例应是一个可审计的候选优先级工作流，而不是“空间图 + docking 图”的拼图。建议流程如下：

1. 从冻结的空间数据中定义样本、切片、区域和生物学重复，预先规定 QC、空间邻接和显著性阈值。
2. 从空间差异或空间变异结果得到候选 ligand/receptor/target；记录全部候选和排除原因，不只保存最后一个漂亮候选。
3. 将基因/蛋白/配体 ID 映射到物种一致的结构记录，记录 PDB/mmCIF/SDF 的版本、来源、结构质量和 preprocessing。

4. 在独立计算环境中运行 docking 或读取已锁定的 docking 结果，使用 decoys、negative controls、重复搜索或多引擎敏感性分析。
5. 把空间定位、表达/蛋白事实、结构接触和文献证据分别写成 typed claims，并由验证器检查 scope、ID、数值和 evidence role。
6. 输出候选优先级和限制，而不是“已证明结合/激活/治疗有效”；必要时提出原位杂交、蛋白验证、结合实验或扰动实验作为后续验证。

4.3.4 必须加入的负对照和评价

挑战	目的	最低结果
随机空间标签/打乱区域	检查空间共定位 claim 是否依赖真实结构	空间统计显著性和 false-positive rate
结构 decoy/非靶蛋白	检查 docking score 是否仅反映结构或口袋偏好	target-vs-decoy discrimination 和 CI
无关配体/负配体	检查模型是否把任何 ligand 都写成支持	wrong-binding claim rate
物种/组织错配证据	检查 evidence scope	wrong-species/wrong-tissue rejection rate
表达高但 docking 差	检查跨层冲突是否被保留	conflict correctly reported，不强行整合
docking 好但空间不表达	检查结构证据是否被误写成组织机制	dataset-support claim must fail or remain partial
不同引擎/参数	检查 score 的方法依赖	sensitivity table，不合并成单一真值

4.4 修复内部序列化精度并固定 artifact manifest

当前 R/utils.R 的 .json 使用 digits=10，而规模实验脚本另行使用 digits=17。这会导致包默认工作流和研究脚本的数值传递契约不一致。应把精度作为显式的内部协议，不依赖模型自行恢复小数。

- 把用于模型和 manifest 的 JSON 精度固定为 17 位；显示文本可以继续使用 .fmt_num() 舍入。
- 在 bio_context_payload() 中记录 serialization_version、precision_digits、payload_chars、input_summary_hash 和 facts_hash。
- 对 PCA variance_explained、极小 p、零值、整数和字符串分别做回归测试。
- 每次模型请求保存 prompt hash、context hash、config public hash、model label、provider host、时间、usage 和 response hash；不保存 key。
- 研究评分程序读取同一 manifest，不再在不同脚本中重复定义精度和容差。

```
# 目标：同一 facts 在包、实验和报告中的数值来源一致
manifest <- bio_context_manifest(ctx, include_hashes = TRUE)
payload <- bio_context_payload(ctx, precision_digits = 17)
stopifnot(identical(manifest$facts_hash, hash_facts(payload$facts)))
```

4.5 明确隐私和执行安全边界

包目前做了很多有价值的脱敏，但它不是自动隐私认证系统；Shiny 和 callr 都与当前用户共享文件/网络权限。论文应该避免“安全沙箱”“隐私保证”等泛化措辞，改成可审计的发送字段和运行权限声明。

- 增加 payload allowlist：只允许 facts、有限 top features、study metadata 的明确字段进入模型；对 feature/cluster/term 标签提供 hash 或用户选择。
- 增加 secret/PII/样本名/条码注入测试；测试不仅检查常见 PATIENT_ 字符串，还检查用户自定义字段和路径。

- 报告对象和原始代码分开：默认 report 不含值，但 bio_record 对象本身仍可能含返回值和完整代码，文档要明确这一点。
- 研究基准中的代码代理运行必须通过 Docker/Apptainer 或等价 OS 层策略，禁用网络和写入项目之外的路径；BioExplainR 的 callr 结果不能代替该基准。
- 将 host = 0.0.0.0 的工作台只作为高级部署说明，补充认证、TLS、反向代理和单租户约束。

五、独立评价设计：从事实传递升级为科学效果

现有 120 案例/480 facts 保留，但在新论文中必须明确归类为 protocol fidelity/serialization stress test。它可以证明 facts 被传递后没有被模型改写，不能证明模型独立完成统计解释。新的评价需要把“答案已给出”与“模型根据事实作出正确判断”分开。

5.1 五层评价终点

层级	问题	输入是否含目标答案	主要终点	论文位置
A 软件接入	adapter 是否提取正确 facts	否；参考值独立计算	exact agreement、缺失和错误率	主文方法/结果
B 协议保真	模型是否复制已提供 facts	是；明确标注为 transport	coverage、exact match、precision	主文次要结果/补充
C 统计判断	模型能否正确区分 raw/padj、效应、重复单位、batch、ORA/GSEA	提供情境和 facts，不提供目标标签	专家金标准 accuracy、unsupported rate	主文主要结果
D 证据支持	文献/数据库是否真正支持 claim	提供混合的支持、矛盾、定义-only 证据	support precision/recall、专家一致性	主文主要结果
E 工作流收益	研究者是否更快、更准、更校准	实验组/对照组不同工作流	任务正确率、时间、信心校准、负荷	主文或独立用户研究

5.2 独立 claim-level benchmark

建议最低规模：100–200 个 claim，来自 8–12 个真实公开数据/分析对象，至少覆盖 bulk RNA-seq、单细胞和一个跨模态案例。每个 claim 由两名以上领域专家在模型运行前标注。测试集不能参与 adapter、prompt 或规则开发。

任务家族	建议样本量	错误类型	最低报告
差异表达	30–40 claims	raw vs adjusted p、方向、阈值、NA padj、effect vs significance	accuracy、false claim rate、per-case CI
富集/GSEA	20–30 claims	ORA activation、NES direction、background、redundancy	statistical interpretation accuracy
单细胞设计	20–30 claims	cell vs donor、batch、cluster marker、UMAP distance	design error detection
图形映射	20–30 claims	raw p、axis transform、subset、color/size	mapping pass/fail、false pass
跨模态	30–50 claims	sample mismatch、discordant directions、derived evidence、causal overclaim	joint claim accuracy and support
空间 + 结构	30–50 claims	空间共定位、区域分母、ligand/receptor scope、docking score、decoy、结构证据过度解释	spatial/structure claim accuracy、false mechanism rate、conflict handling
错误诊断	40–60 cases	missing package/object/column、dimension、S4、ID、factor、counts、NA	top-1/top-3 root cause accuracy

比较方法至少包括：普通模型 + 相同问题文本、BioExplainR 本地模板、BioExplainR facts-only、BioExplainR facts + evidence、facts + validator/revision。所有方法固定模型版本、温度、token、prompt 和成本记录。普通模型不能被故意给弱输入；如果输入预算不同，必须把它作为预注册的资源约束并报告。

5.3 证据支持关系评价

当前 evidence_used 只检查模型是否引用了供应集合中的 ID。下一步要为每个 claim 构造四类 evidence：支持、矛盾、仅定义、无关。专家在不看模型方法的情况下判断 claim 是否得到支持，并记录物种、组织、实验条件和结论强度。

- 不要把 Europe PMC 的搜索命中当作 support；文献标题和全文结论必须分开。
- GO/Reactome/KEGG term definition 只能满足 definition_only，不能满足 pathway_activity 或 dataset_effect。
- UniProt annotation 只能支持 annotation/membership 类型 claim，不能直接支持处理组差异或因果。
- 报告 evidence precision、support recall、wrong-species rate、definition-as-support rate 和 citation coverage。
- 至少两名专家独立标注，报告 Krippendorff alpha 或适合的多评分者可靠性指标；exact agreement 作为补充。

5.4 错误诊断、图形和修复评价

组件	现有状态	新增评价	验收线
错误诊断	离线规则单测	60 个真实/盲法构造错误；根因由专家预标注；模型和规则盲评	top-1 ⩾ 0.75，top-3 ⩾ 0.90；未知错误不强行归类
图形核对	9 个预设 challenge	40–60 个真实图/注入图；包括 facet、coord、subset、multi-layer、label	false-pass < 5%；not_checkable 单独报告
修复验证	显式不变量和 callr	错误方向、行数、列、design、输出类型的候选修复集	运行率和语义率分开；无 invariants 不计成功
声明验证	value/path/direction/ citation	typed claim ledger + 语义负例 + 未声明 prose	对注入错误 recall ⩾ 0.95；自由 prose 保持 unverified

六、真实多组学案例：iMeta 送审的必要主结果

主案例必须有一个真正的生物学问题，而不是把多个对象并排展示。推荐结构是“同一批样本的两个或三个模态，存在缺失样本、批次或方向不一致的现实困难；BioExplainR 识别这些困难并限制模型结论”。

主案例章节	必须展示	避免的写法
数据与设计	样本交集、模态缺失、donor/group/timepoint/batch、独立重复	只报每个对象的 feature 数量
对象接入	MultiAssayExperiment/SCE/SE/结果表如何映射到 context	声称支持所有上游版本
模态内 facts	每个模态的差异、QC、阈值、来源和不确定性	把不同模态的 p 值简单合并
跨模态整合	agreement、discordance、derived edges、样本/feature 对齐	方向一致就写成共同机制
证据	支持/矛盾/定义-only 证据和适用范围	把数据库定义写成实验激活
模型输出	原始 prose、typed claims、验证状态和人工修订	只展示完美示例

主案例章节	必须展示	避免的写法
结果价值	错误率、时间、专家判断或用户任务收益	用 100% facts transfer 代替生物学效果

可接受的第一版不必覆盖所有 omics。一个严格完成的 transcriptome + methylation/CNV 或 transcriptome + proteome 案例，优于五个没有样本对齐和专家评价的模态 demo。若选择微生物组/代谢组/转录组，应提前确定 feature ID、物种、批次和 compositionality 的解释边界。

七、正式人类评价设计

当前 30 位功能评分和 3 位外部评分者的聚合数据只能作为 pilot 或可接受性信号。若要把用户收益写进一区论文，应在收集前完成伦理审查/豁免判断、知情同意、招募标准、补偿、数据保留和预注册。

设计元素	最低要求
人群	初级或中级生物信息学研究者；记录 R/生信背景和先验能力
分组	BioExplainR 工作流 vs 原始 R 输出或普通 LLM；同一数据和时间预算
任务	差异表达、富集/单细胞设计、图形判断、一个跨模态任务；加入未见数据迁移
终点	主要：任务正确率；次要：完成时间、信心、信心-正确性校准、NASA-TLX/SUS
盲法	评分者不知道组别；答案密钥和分组表分开保管
样本量	由预注册效应和功效计算决定；不要用当前便利样本的 91.98 分倒推效果
统计	pre/post 或任务分数使用混合效应模型/预设分析；报告效应量和置信区间
伦理	真实审批或豁免编号、同意、招募、补偿、匿名化和数据管理

如果短期内无法完成正式用户研究，论文应明确不声称用户收益，把教学模块和当前功能评分放入补充材料或另一个后续研究。iMeta 的主论文可以只依靠独立专家 claim benchmark + 真实多组学案例，但不能同时使用“帮助初级研究者”作为已证实结论。

八、统计分析与预注册方案

项目	建议预注册内容
主要终点	unsupported biological claim rate 或 statistical/design error rate；定义分母和 claim 单位
主要比较	BioExplainR facts+evidence+validator vs fair baseline；模型、版本、温度和 prompt 冻结
事实终点	adapter agreement 与 transport fidelity 单独报告，不能合并为模型 accuracy
专家评分	每个 claim 的 0/1 或 0–2 标准、双评者、冲突裁决和 alpha/ICC
置信区间	按 case/bootstrap 或 mixed-effects 结构计算，不把重复调用当独立生物样本
多重比较	主终点只设少数；其余为探索性并报告 BH 或不调整说明
成本	输入/输出 tokens、网络时间、失败重试、每个正确 claim 成本
缺失	模型不回答计为未完成，不填补；解析失败与事实错误分别统计
开发隔离	开发案例、提示调参、阈值选择和最终 test case 的时间线可审计

建议的主要效应表达：相对于公平 baseline，BioExplainR 将 unsupported/incorrect claim 的风险降低多少；同时报告 absolute risk difference、relative risk、95% CI 和每个任务家族结果。不要把 480 个共享程序生成事实看成 480 个独立样本进行显著性检验。

九、论文重构方案

9.1 推荐中心题目

英文题目候选

BioExplainR: deterministic, evidence-constrained and claim-verifiable interpretation of integrated omics results

中文对应：BioExplainR：面向整合组学结果的确定性事实、证据约束与可验证声明解释框架。题目中的 integrated omics 只有在 MultiAssayExperiment/真实跨模态案例完成后才能使用；否则改为 omics R analysis objects。

9.2 主文结构

章节	应写什么	不应写什么
摘要	问题、架构、跨模态案例、独立 benchmark、主要风险降低结果	74 个函数清单、模型 100% 复制事实
引言	组学解释的事实/证据/因果错配；现有 LLM 工具缺口；本文假设	泛泛介绍 AI 热点
方法	context contract、typed claims、evidence roles、验证政策、数据和盲法	把结果数字写进方法
结果 1	软件接入和确定性事实 conformance	把 R 事实当模型能力
结果 2	独立 claim benchmark 和公平 baseline	只展示成功案例
结果 3	空间转录组 + 结构层案例和冲突识别	把共定位或 docking 写成已证实机制
结果 4	专家/用户任务结果（若完成）	用便利功能评分替代任务正确率
讨论	适用边界、未验证 prose、证据支持限制、模型漂移、隐私和 sandbox	宣称临床、教学或因果收益

9.3 图表设计

图/表	建议内容
Figure 1	跨模态 R objects → contexts → fact/claim/evidence graph → validation/report；标明 local/model/verified 边界
Figure 2	公平 baseline 的 statistical/design/unsupported claim 错误率；显示独立 test set 和 CI
Figure 3	真实多组学案例：sample map、模态内结果、跨模态一致/冲突、验证状态
Figure 4	证据角色和 claim validation 的 confusion matrix / precision-recall；不是只画 100% pass
Table 1	与相关工具的设计差异，明确不是性能排名
Table 2	软件 conformance 和版本矩阵
Table 3	独立 claim benchmark 的逐任务结果
Table 4	人类专家/用户评价设计和效应估计
Supplement	所有 prompts、case manifest、逐 claim labels、审计日志、原始脱敏输出和复现环境

十、逐文件改造清单

文件/目录	改动	完成标志
R/utils.R	统一 JSON precision、hash、manifest、脱敏字段策略	新增 precision/hash 回归测试；

文件/目录	改动	完成标志
		研究和包使用同一序列化
R/context.R	扩展 context provenance、modalities、sample map 和 manifest	MultiAssay/context conformance 测试通过
R/adapters-spatial.R（新增）	SpatialExperiment/Seurat spatial、坐标/区域/QC/空间结果 adapter	真实切片对象、空间结果表和脱敏 payload 通过
R/docking.R（新增）	读取 docking 输出、结构/引擎/参数 provenance、pose/decoy facts；不内置未经审计的引擎执行	多引擎/负对照/结构 hash 的 conformance 测试通过
R/explanation-validation.R	typed claim ledger、claim policy、causal default unverified	注入错误 recall 和自由 prose 状态正确
R/evidence.R / evidence-live.R	evidence role、support annotation、scope/organism matching	support/contradict/definition-only 单测和专家数据接口
R/project.R	跨模态依赖、sample alignment、conflict/derived evidence	真实多组学项目端到端报告
R/validate.R	保留 callr 警告；增加外部 sandbox backend 接口或明确研究端隔离	安全边界文档与 sandbox 研究基线
R/record.R / runtime.R	artifact manifest、session/config/prompt/response hash	报告可重建且无 key/PII
R/plots.R / plot-cross-check.R	扩展代表性 plot mappings；完整覆盖和 false-pass 统计	自然/注入图 benchmark
tests/testthat	增加 multiomics、precision、claim、evidence support、privacy、manifest 测试	R CMD check 和 CI 全绿
research/	新建 frozen benchmark、label schema、expert adjudication、independent test runner	开发/测试集隔离并有 manifest
research/audit_results.R	改为审计 main_scale_480 和新 benchmark；历史结果单独入口	不会再读取旧 225/54 结果
README.md / docs/ROADMAP.md	删除历史数字或明确 historical；更新当前 525/120/480 状态	grep 不再发现无标签旧主实验结论
DESCRIPTION	补真实作者、维护者、URL、BugReports、版本和 DOI 发布信息	可公开安装和引用
GitHub/Zenodo/CI	公开仓库、release、DOI、R CMD check matrix、artifact upload	第三方按 README 从零复现

十一、按周执行计划

时间	工作包	交付物	停/继续判断
第 0 周	冻结 0.3.1、清理历史状态、公开发布准备、修复审计脚本	clean branch、版本 manifest、单一结果目录	若旧数字仍混入论文，停止投稿路线
第 1–2 周	precision + manifest + typed claim ledger skeleton	新 API、schema、单测、示例报告	P0 软件契约通过才进入 benchmark
第 2–4 周	MultiAssayExperiment/sample map/context 适配	一个真实多组学对象和端到端 project report	若数据不匹配，换数据，不拼接
第 3–5 周	SpatialExperiment/Seurat spatial 与 docking provenance adapter	空间 context、结构 context、negative-control schema	结构层只做结果审计，不自动运行不受控 docking
第 3–6 周	冻结 claim benchmark 和 evidence support labels	case JSON、答案标准、专家标注模板、预注册	标签一致性不足则先修 rubric
第 5–8 周	运行公平模型 baseline 和 BioExplainR 条件	原始 prompts/responses、cost、latency、逐 claim scores	任何调参后 test 集必须重冻
第 6–9 周	专家盲评、错误诊断/图形 benchmark	匿名评分、alpha/ICC、false-pass 分析	不能把方便样本结果写成用户收益
第 8–10 周	空间转录组 + 结构层主案例和冲突/证据图	Figure 1/3、Table 2/3 草稿	没有真实空间主案例则转投软件期刊路线
第 9–11 周	用户任务研究或正式伦理材料	预注册、审批/豁免、任务数据和分析脚本	伦理未完成则不报告

时间	工作包	交付物	停/继续判断
			user benefit
第 11–13 周	统计分析、论文重写、补充材料和 artifact	英文主稿、supplement、repo、DOI	全部主张能回到原始记录
第 13–14 周	第三方复现、内部红队审稿、期刊格式	reproducibility report、response-to-reviewer 预案	P0/P1 未清零则不投 iMeta

十二、iMeta 与一区备选投稿决策树

期刊分区会随年份、数据库和学科类别变化，投稿前必须用当年 JCR/CAS/期刊官网核验。以下是基于主题匹配和方法学要求的路线选择，不是对分区或录用的保证。

完成状态	首选	备选	稿件叙事
多组学案例 + 独立 claim benchmark + evidence support + 正规用户/专家研究	iMeta	Briefings in Bioinformatics、PLOS Computational Biology（按当年分区和 scope 核验）	integrated omics reliability layer
多组学案例 + 强 benchmark，但没有正式用户实验	iMeta 或 NAR Genomics and Bioinformatics	Bioinformatics	reproducible computational method with independent validation
只有转录组/单细胞 + 强 claim benchmark	Bioinformatics / NAR Genomics and Bioinformatics	PLOS Computational Biology	verifiable interpretation of bioinformatics objects
只有软件 QA、transport fidelity 和机制 challenge	Bioinformatics Advances / BMC Bioinformatics 等软件方法期刊	不应把 iMeta 当作唯一目标	software framework and reproducibility

最低 iMeta 送审门槛

至少同时满足：一个真实匹配多组学案例；独立 test set 的 claim-level 结果；公平 baseline；证据支持关系评价；公开 repo/DOI/环境；所有 P0 清零；当前人类评价不再被夸大；论文不把 transport fidelity 当模型推理能力。

十三、80 分投稿准备度评分表

这是团队内部的 go/no-go 评分，不是录用概率。若总分未达到 80，或者任一 P0 未完成，不建议投 iMeta。达到 80 也只能表示材料足够成熟，可以进入编辑筛选和同行评审。

维度	权重	80 分门槛	当前估计	补齐动作
iMeta/组学主题匹配	15	真实跨模态主案例和明确科学问题	6	MultiAssay + matched omics case
独立科学证据	25	冻结 test set；claim/evidence/diagnosis 指标和 CI	8	100–200 claims、专家标注、fair baselines
方法创新与可解释边界	15	typed claims、证据角色、冲突和不确定性可验证	10	claim ledger + support policy
软件和复现	15	公开 repo、DOI、CI、container、R CMD check、artifact manifest	10	发布和第三方复现
人类评价	10	伦理/招募/任务正确率/盲法或正式专家评价	2	预注册和真实任务研究

维度	权重	80 分门槛	当前估计	补齐动作
论文主张一致性	10	无历史数字、无过度 claim、主次终点分开	5	重写主稿和审计器
数据与伦理/作者信息	10	作者、基金、COI、伦理、数据管理全部真实填写	3	投稿前核验并补齐
合计	100	≥80 且 P0=0	44	预计 12–14 周集中改造

十四、最终投稿前验收清单

软件

- ☐ R CMD check --as-cran 无 ERROR/WARNING；testthat 和 optional-dependency matrix 有记录
- ☐ 精度、隐私、claim schema、证据角色、MultiAssay 对象、图形和修复验证测试通过
- ☐ 所有 exported functions 的 Rd、README、用户指南和示例一致
- ☐ 没有把 callr 或 Shiny 描述为 OS sandbox；网络和文件权限边界写清楚

研究

- ☐ 开发案例、调参案例和最终 test set 有时间戳和 hash；最终 test set 未参与开发
- ☐ transport fidelity、statistical interpretation、evidence support、user benefit 分开计分
- ☐ 每个主结论有 reference facts、原始响应、评分记录、脚本和 manifest
- ☐ 模型版本或可复现实验日期、prompt、token、temperature、cost 和失败重试全部记录

多组学

- ☐ 样本交集、缺失模态、批次、donor、group 和 timepoint 都有数据表
- ☐ 至少一个真实匹配的 SpatialExperiment/Seurat spatial 案例可在干净环境重建
- ☐ 空间统计记录 spot/区域分母、邻接定义、切片/样本层级和空间 QC
- ☐ 若接入 docking，结构文件、引擎、参数、pose、decoy 和 negative control 全部可追溯
- ☐ 跨模态一致方向、空间共定位和 docking score 都不被写成因果或实验结合；派生证据和独立证据明确分开

人类与伦理

- ☐ 真实招募、参与者背景、知情同意、补偿和伦理审批/豁免已核实
- ☐ 专家评分保留匿名原始数据，报告适合的可靠性指标和裁决流程
- ☐ 用户任务有对照、正确率、时间和预注册的主终点；没有就不写用户收益

投稿材料

- ☐ 作者、单位、通讯邮箱、CRediT、基金、利益冲突和 AI 使用声明真实完成
- ☐ GitHub release、Zenodo DOI、LICENSE、container/renv.lock、CI 和复现说明公开
- ☐ 主文、补充材料、图表、原始 records、代码和哈希一致；审计器使用当前冻结目录
- ☐ iMeta scope 和当年分区核验完成；同时准备 Bioinformatics/NAR G&B/PLOS Comp Bio 路线版本

十五、明确不要做的事

- 不要把 facts_only/facts_evidence 的 100% 写成模型具有 100% 生物信息学解释准确率。
- 不要把程序生成的 120 个案例写成 120 个独立生物学样本，也不要把三轮重复当成独立样本推断。

- 不要把当前 3 位评分者和 30 位功能评分的聚合结果写成正式用户实验、学习增益或临床效用。
- 不要把数据库 term definition、Europe PMC 搜索命中或 UniProt annotation 自动写成实验通路激活/机制证据。
- 不要把 iSEE、GPTCelltype、ellmer 的入口测试写成相近工具性能排名。
- 不要在没有真实空间/多组学主案例前使用 integrated omics 作为论文核心标题。
- 不要把空间共定位、ligand-receptor 表达或 docking score 单独写成真实分子结合、通路激活或治疗机制。
- 不要把不同 docking 引擎的 score 放在同一尺度直接排名，也不要忽略 decoy、构象和口袋定义的敏感性。
- 不要继续用功能数量替代科学问题和独立终点。
- 不要上传 token、API key、原始患者/样本标识或未脱敏评分文件。

附录 A：74 个导出函数的当前功能地图

功能组	函数
模型配置与调用（13）	bio_config; bio_configure; bio_get_config; bio_reset_config; bio_presets; bio_register_preset; bio_unregister_preset; bio_endpoint_url; bio_llm_available; bio_build_request; bio_llm_chat; bio_parse_response; bio_redact
对象解析与适配器（6）	bio_context; new_bio_context; bio_context_payload; bio_adapters; bio_register_adapter; bio_unregister_adapter
解释与声明（2）	bio_explain; bio_validate_explanation
证据与来源（13）	bio_evidence; bio_evidence_register; bio_evidence_list; bio_evidence_clear; bio_evidence_lookup; bio_register_evidence_provider; bio_fetch_evidence; bio_evidence_for_context; bio_evidence_providers; bio_register_live_providers; bio_evidence_cache_clear; bio_go_annotations; bio_dependency_provenance
图形与组成（7）	bio_plot; bio_plot_pca; bio_plot_umap; bio_plot_enrichment; bio_plot_heatmap; bio_cross_check; bio_cell_proportions
记录、诊断与修复（16）	bio_record; bio_record_code; bio_records; bio_value; bio_last_error; bio_explain_error; bio_suggest_fix; bio_validate_fix; bio_invariant; inv_class; inv_equal; inv_factor_levels; inv_has_columns; inv_no_na; inv_nrow; inv_same_nrow_as_input
运行环境、项目与报告（6）	bio_runtime_info; bio_object_inventory; bio_package_usage; bio_project; bio_explain_project; bio_report
教学与评估（10）	bio_question_bank; bio_quiz; bio_grade; bio_review_rubric; bio_benchmark; bio_benchmark_fixes; bio_evaluate_experts; bio_evaluate_learning; bio_plan_learning_study; bio_randomize_learning_study
工作台（1）	bio_run_app

附录 B：建议的第一轮新目录

```
research/
  frozen_benchmark/
    cases/                  # 开发集和 test 集分离
    claim_schema.json
    evidence_labels.csv
    expert_adjudication.csv
    benchmark_manifest.json
  multiomics/
    download_manifest.csv
    sample_map.csv
    run_multiomics_case.R
  run_claim_benchmark.R
  run_evidence_support_benchmark.R
  run_error_diagnosis_benchmark.R
```

```
    run_plot_audit_benchmark.R
    audit_current_results.R
    results/
      frozen_v1/
        prompts/ responses/ scores/ manifests/
  docs/
    PAPER_DRAFT.md
    SUPPLEMENTARY_MATERIAL.md
    DATA_DICTIONARY.md
    ETHICS_AND_HUMAN_EVALUATION.md
    REPRODUCTION.md
```

结论

BioExplainR 现在已经具备一篇扎实软件方法学论文的骨架，真正的短板不是代码量，而是主张与证据不在同一个层级：软件提供了声明和证据的检查接口，但当前研究主要验证接口机制；论文想进入 iMeta 或其他一区，需要把这些接口用于独立的真实多组学科学问题，并量化它们是否减少统计误读、无支持生物学表述和证据错配。

最推荐的路线是：先把 0.3.1 冻结为 reproducibility baseline，修复历史审计和 JSON 精度问题；然后完成 typed claim ledger、证据支持关系和一个真实匹配多组学案例；接着运行开发集完全隔离的 claim-level benchmark，并在条件允许时完成伦理完整的用户任务研究。只有当 P0 清零、内部投稿准备度达到 80/100、主文每个数字和主张都能回到独立记录时，再把 iMeta 作为首投，并准备 NAR Genomics and Bioinformatics、Bioinformatics 或 PLOS Computational Biology 的针对性版本。