BioExplainR：已有 R 生物信息学对象的确定性事实驱动与可检查解释框架

面向英文方法期刊的中文初稿 v0.7

2026-10-05

摘要

动机： 初级生物信息学研究者能够运行分析代码，却可能难以判断结果中的比较方向、统计阈值和生物学含义。我们开发 BioExplainR，将统计计算保留在 R 侧，再由本地模板或可选模型组织具有来源状态的解释。

方法： 我们将输入对象的事实提取、模型语言组织、声明/图形核对和修复不变量分别实现；在五个公开数据集（airway、PBMC3k、pasilla、ALL 和 bladderbatch）上进行分层对象接入与事实核对，并以 120 个可复现案例、480 个目标事实、三种输入方法和三轮重复调用评价事实传递，再以外部评分者聚合评价和浏览器自动化记录软件行为。外部评价数据仅作描述性功能感知分析。

结果： airway 在 $P_{adj} < 0.05$ 且 $|log2FC| > 1$ 时得到 999 个显著特征，其中上调 519 个、下调 480 个。主实验共完成 1,080 次 DeepSeek 请求和 4,320 条逐事实评分；有界原始输出严格匹配 437/1,440（30.35%），覆盖率为 35.83%，已回答准确率为 84.69%，R 事实摘要和 R 事实加证据均为 1,440/1,440（100%）。StepFun 与 DeepSeek 的双模型规模任务各为 480/480；独立 pasilla 数据的 30 项事实核对全部通过。3 位外部评分者对 30 个匿名解释案例的 720 条评分总体均值为 1.751/2，case-dimension 完全一致率为 93.75%；30 位评分参与者对 5 项功能的 150 条功能感知评分总体均值为 91.98/100，144/150（96.0%）标记为有用。

结论与可用性： 在本研究的固定输入和受控挑战中，BioExplainR 保留了确定性事实、来源和检查状态；这些结果不证明模型自由文本、生物学解释或真实用户收益。外部评分是未预注册、无对照任务的描述性功能感知评价，不是随机对照、SUS、学习增益或临床效用证据。软件采用 MIT 许可证，验证环境为 R 4.3.3、BioExplainR 0.3.1；公开代码仓库、发布 DOI 和通讯作者信息待作者补齐。

关键词： 生物信息学；R；大语言模型；确定性事实；可追溯解释；声明验证；Shiny

1 引言

RNA-seq 与单细胞分析依赖多个 R/Bioconductor 软件包：DESeq2、limma 和 edgeR 实施统计推断，Bioconductor、SingleCellExperiment 和 Seurat 组织实验对象，ggplot2 表达图形映射 [1-7]。这些计算结果仍需解释。本文将初级生物信息学研究者（primary bioinformatics researchers）定义为能够运行 R 代码、但尚不能独立判断统计与生物学含义的用户。其常见困难包括把文库数或细胞数当作独立重复、混淆原始与校正 P 值、反转比较方向，以及从富集显著性直接推断通路激活。

面向生物信息学的大语言模型工具已覆盖细胞类型标注、工作流辅助、基因集解释和通用代理。GPTCelltype、SCassist、GeneAgent 和 AnnDictionary 分别研究这些任务及其评价 [8-11]；BioChatter、Biomni 和 BioMaster 连接知识资源、任务规划与代码执行 [12-14]。iSEE 提供实验对象交

互探索，ellmer 提供 R 中的模型调用基础设施，llm2geneset 结合模型生成基因集与过度表示分析 [15-17]。CASSIA、scExtract 等工作进一步扩展了单细胞标注与分析 [18,19]。这些方向与“解释已有 R 对象并留下可检查记录”相关，但评价对象不同，不能把任务自动化、标注准确率和统计事实传递混作一个指标。

已有对象的解释入口还面临一个具体信息问题：完整矩阵或结果表不宜直接送入模型，而仅提供顶部行又不足以确定全表计数；即使完整提供一个子表，逐行精确计算也属于可由 R 直接完成的工作。一般性生成文本的流畅度不能保证事实正确 [20]。因此，需要明确区分上游统计计算、摘要生成、语言组织和验证状态，而不是用一个总体“可信度”代替它们。

我们提出 BioExplainR，将统计计算保留在 R 侧，把可选模型限定为基于有界摘要组织语言，并提供显式声明验证、图形交叉核对与修复不变量检查。贡献是三个相互连接的工作流设计：带来源状态的统一对象摘要；事实、引用、图形及修复的分项检查记录；连接代码执行、解释与报告的本地工作台。我们以 120 个可复现案例、480 个目标事实评价三种输入条件，并以两个 OpenAI-compatible 模型运行相同规模的共同任务；另加入外部评分者案例评分和功能感知评分，报告协议边界、受控挑战结果、语义负例与未覆盖边界。工具的设计比较见表 1；相近工具仍不作共同任务性能排名。

2 方法

2.1 研究设计与评价终点

本研究是软件方法学研究，包含四个相互区分的评价层级：系统功能与对象接入验证、固定案例的结构化事实传递消融、未参与 airway/PBMC3k 开发的 pasilla 数值事实核对，以及外部评分者的描述性功能感知评价。另以浏览器自动化检查工作流连通性和页面状态。软件测试、受控机制挑战、独立数据核对和外部评分不共享同一性能终点，也不互相替代。

预先定义的主要软件终点是：适配器从 R 源对象提取的事实与独立 R 计算值一致；模型响应中的目标 fact-path 和标量值按固定容差匹配；声明、图形映射和修复不变量返回预设状态。辅助终点包括结构化响应覆盖率、已回答准确率、响应时间、协议解析状态和功能感知评分。所有模型实验使用固定案例、提示和保存的参考事实；结果按重复调用报告描述性统计，不进行超出实验设计的泛化推断。

2.2 系统架构

BioExplainR 0.3.1 接收已有 R 分析对象、用户提供的实验背景以及可选源结果。专用适配器将输入转化为 `bio_context`，记录分析类型、来源类与包、来源状态、确定性事实、有界顶部行、图形映射、参数和不确定性；有界 JSON 载荷分别供本地解释或可选模型使用。解释、检查结果和来源共同进入 HTML、Markdown/Quarto 报告与 Shiny 工作台（图 1）。

支持的接口包括 DESeq2 `DESeqResults`、limma `MArrayLM`、edgeR 检验对象与 `TopTags`、ORA/GSEA 风格对象、clusterProfiler 风格富集对象
[21]、Seurat、SingleCellExperiment、SummarizedExperiment、`prcomp`、ggplot 与矩阵。多系数 limma 拟合必须指定系数；普通表格的列名只提示可能来源，不能确认生成软件。完整输入在 R 侧用于适用的统计事实计算，原始矩阵不随模型载荷发送。大矩阵的部分诊断采用有界取样或稀疏存储摘要，并标记检查范围，不能将其表述为全矩阵审查。实际测试版本与接口支持范围分别记录，避免把“可适配”写成“所有版本均已验证”。

2.3 确定性事实与分层解释

差异表达适配器从完整提供的结果计算特征数、校正 P 值缺失数、筛选数量和方向。对于校正阈值 α 与效应阈值 τ，显著集合为同时满足非缺失 P_{adj}、$P_{adj} < \alpha$ 和 $|\log2FC| > \tau$ 的特征，上调与下调由集合内效应值的正负确定。P_{adj} 表示输入的校正 P 值；其计算方法沿用来源，或在用户明确指定时另行计算。缺少校正值时记录 raw-only 状态，不以原始 P 值冒充校正值。BH 校正遵循既有方法 [22]；DESeq2 的独立过滤可能产生缺失校正值，不能据此断言没有原始检验或没有变化 [1,23]。

输出解释包含数据事实、统计含义、生物学候选解释、不确定性和不能推出的结论。本地模板可离线运行；模型接收已经计算的事实，不承担全表重算。PCA 方差比例保留计算精度，显示文本可另行舍入；顶部预览采用有限有效数字。该模块保证摘要计算规则可检查，不保证上游设计、用户背景或模型自由文本正确。

2.4 证据与声明验证

用户显式开启检索后，系统可访问 Europe PMC、QuickGO、Reactome、KEGG 与 UniProt [24-28]，将来源 ID、标题、URL、访问时间和提供方式保存为证据对象。输出提供来源追踪入口；检索命中、数据库注释和论断支持是不同概念，系统目前不自动全文审读或评价证据支持强度。

模型按统一要求返回分节 JSON 及 `claims` 数组。验证器接收解释、上下文和给定证据集合，核对事实路径是否存在、值是否为可比较标量、数值或方向是否一致，以及引用 ID 是否属于该集合。非零参考值使用 10^{-6} 的相对容差，参考为零时使用 10^{-6} 的绝对容差；字符串精确匹配。顶部表路径核对的是保存的有界预览值。结果为 `pass`、`fail`、`partial` 或 `unverified`；没有显式声明的文字不记为通过。引用闭集检查不证明文章支持论断，声明通过也不验证未声明的措辞、因果解释或整段文本。

2.5 图形核对、执行记录与修复不变量

图形核对接收 ggplot 与独立提供的源对象，输出所检查映射的一致性状态。火山图按 ID 或可配对行检查效应方向与 P 值来源；BioExplainR PCA 图核对坐标、解释方差和轴标签，提供元数据时可核对分组；富集气泡图按条目 ID 检查标签、比例、Count、颜色与大小。允许预期子集需显式指定；复杂多点图层或不能配对的情况返回 `not_checkable`。核对针对标度和坐标变换前的映射值，不覆盖全部像素、裁剪、人工注释或视觉误导。

执行记录保存运行状态、警告、错误现场调用栈、对象摘要及包调用表达式。用户显式提交的修复代码在独立 R 进程运行，依据事先声明的类型、行数、因子水平等不变量检查输出；未设置不变量时，运行成功仅标为 `runtime_only`。不变量检查能拒绝违反指定条件的修复，不能证明所有语义保持；独立进程隔离会话状态，但不是操作系统安全沙箱。

2.6 Shiny 工作台

工作台基于 Shiny [29]，接收模型配置、用户 R 代码及工作区对象，提供运行环境、代码记录、对象解释、PCA/UMAP/富集/热图和报告下载。生成图形保存回会话工作区，可由用户选择源对象核对。每个浏览器连接拥有独立工作区副本、页面配置和运行记录。该设计可检查工作流连通性与浏览器连接间的页面状态隔离，不构成共享 R 进程文件、网络或包权限的多租户隔离。截图与自动化验证见补充图 S1 和补充材料 S7。

默认解释语言和 Shiny 界面为 English；用户可通过 `language = "zh"` 或界面选择切换为简体中文。primary bioinformatics researchers 可按需使用中文术语入口；语言选择只改变用户可见措辞，不改变 R 计算事实、检查状态或评分规则。这是界面设计选择，不是语言能力或跨语言性能声明。

2.7 数据集、预处理与统计流程

airway。 使用 airway 1.22.0 的 GSE52778 计数对象，来源为人气道平滑肌地塞米松研究 [30]。以细胞系作为配对项，使用 `~ cell + dex` 设计、`untrt` 作为参考水平，比较 `trt` 与 `untrt`。差异表达结果使用 DESeq2 1.42.0 的 `results()`；预设筛选阈值为 $P_{adj} < 0.05$，另以未经 LFC shrinkage 的 $|log2FC| > 1$ 作为效应大小筛选条件。该效应条件不是以效应超过 1 为原假设的检验。用于 PCA 的样本和供体结构沿用 airway 对象的配对设计。

PCA 使用 `vst(blind = FALSE)`，从非恒定特征中选择方差最高的 500 个特征，中心化但不标准化。另用 limma 3.58.1 的 voom/经验贝叶斯流程和 edgeR 4.0.16 的准似然流程，在相同过滤和设计条件下生成兼容性对照 [2,3,31]。Reactome ORA 从保存的 Ensembl 映射快照中保留人类且出现在结果中的基因；以有注释基因为背景，对满足预设背景大小范围的通路进行超几何检验，并对全部检验进行 BH 校正。该分析用于验证对象接入和事实提取，不作为 clusterProfiler 上游流程的性能测试。

PBMC3k。 使用 10x Genomics 公开过滤矩阵 [32]，从对象元数据计算每细胞 UMI 数、检测基因数和线粒体比例，并分别构建 SingleCellExperiment 1.24.0 与 SeuratObject 5.0.1 对象。可视化表达按每细胞 10,000 缩放后取 log1p，选取最高方差的 1,000 个特征作 20 维 PCA，再由 uwot 0.1.16 生成 UMAP [33]；随机种子为 20261004，单线程运行，保留公开过滤矩阵中的全部细胞。该流程不实施完整细胞类型注释，不把细胞作为独立生物学重复，也不进行供体间推断 [34]。数据地址、SHA-256 和软件版本见补充材料 S1。

ALL 与 bladderbatch。 从固定的 Bioconductor 数据包归档读取 Biobase `ExpressionSet` 对象 [37,38]。ALL 仅检查表达矩阵维度、表型列和 BT 分组摘要；bladderbatch 另外检查癌症分组和批次字段。两者不在本研究中重新拟合差异表达模型、不进行批次校正，也不将分组摘要解释为生物学效应；完整任务边界和归档哈希见补充材料 S1。

2.8 消融设计、评分与重复结构

本轮规模主实验使用 120 个可复现案例和 480 个唯一目标事实，三种输入方法各重复三轮，共 1,080 次请求和 4,320 条逐事实评分。默认 BioExplainR 工作流在 R 中分析完整对象，向模型传递完整确定性事实和最多 10 行 top-feature 预览；`direct_bounded` 仅作为信息受限基线，不代表默认模型输入。

主实验固定 DeepSeek OpenAI-compatible 服务，请求模型 `deepseek-flash`，关闭 thinking，temperature = 0，启用 JSON mode，输出上限 5,000 tokens，timeout 120 s，瞬时错误最多重试一次 [35]。模型别名没有不可变快照编号，因此该参数设置不保证跨时间完全确定。规模实验包含 120 个可复现案例和 480 个唯一目标事实：差异表达 30 案例、富集 20 案例、PCA 20 案例、SingleCellExperiment 20 案例、细胞组成 15 案例和 generic 表格摘要 15 案例；每案例四个标量目标。案例由 R 程序生成，目标事实由 BioExplainR adapter 从完整输入计算；它们用于验证对象接入、摘要传递和协议行为，不代表 120 个独立生物学样本。

比较三种输入：bounded raw output（`direct_bounded`）只提供维度、有限行或对象结构，不提供完整目标事实；R-computed fact summary（`facts_only`）提供从完整输入计算的事实、来源和最多 10 行 top-feature 预览；R facts plus evidence（`facts_evidence`）额外提供保存的 Europe PMC 记录。三者使用相同输出要求和请求设置，每案例每方法调用三次，共 1,080 次请求；480 个目标每方法重复三轮，形成每方法 1,440 条、总计 4,320 条逐事实评分。原始基线允许无法判断时返回 null；这不是对代码执行代理的测试。完整逐项数据见表 8。

参考值由 R 从每个完整源对象独立计算，不使用模型响应。目标事实匹配率定义为匹配数/目标数，覆盖率为非 null 标量数/目标数，已回答准确率为匹配数/已回答数；未回答记为未完成，不作缺失值填补。每种输入方法对相同 120 个案例调用三次，共 1,080 次请求、4,320 条逐事实评分；重复共享输入和目标，因此只报告描述性匹配率、轮次均值和样本标准差，不将重复评分视为独立数据集或实施独立二项推断。

机制挑战在 18 个事实加证据响应的上下文中分别注入错误数字、未知路径、向量值、未知引用及仅路径无值声明，共 90 项；移除验证器时记录为 `unchecked`。图形挑战预设三张正确图和六种注入错误；修复挑战预设两段可运行代码，分别保持或反转参考水平。挑战指标只针对预设违例，不估计自然错误率或一般修复成功率。主实验提示、配置、评分规则和原始响应均在补充材料 S3-S4 中归档；主实验在一次开发迭代后完成，因此预先承认开发集乐观偏倚。研究报告参照 TRIPOD-LLM 的透明报告原则，但本研究不是临床预测研究 [36]。

2.9 双模型与代码代理共同任务

为进行协议适配对照，使用与规模主实验相同的 120 个案例、480 个目标事实和评分规则。StepFun `step-5-preview`、DeepSeek `deepseek-flash` 各运行一次。模型请求使用 OpenAI-compatible 协议、temperature = 0、最多 800 个输出 token；最终运行对两种模型均关闭 `response_format = json_object`，其中 StepFun 的关闭设置用于避免此前探针中的网关格式不稳定。所有响应均要求返回包含 `fact` 和标量 `value` 的 claims 数组；提示提供完整精度的数值，并要求非整数小数逐字符复制。结果按相同 fact-path、数值容差和覆盖率规则评分，保存逐案例脱敏响应与逐事实评分。该设计只评价结构化事实传递和协议适配，不评价自由文本、生物学推理、长期稳定性或模型排名。

两种模型接收完全相同的输入、prompt、token 预算和评分规则；每个模型均对同一批 120 个案例逐案例调用一次，最大输出为 800 tokens。**Both models received identical inputs, prompts, token budgets, and scoring rules; each model was called once per case.** 因此两者共享同一批 120 个案例、480 个目标事实、提示文本、数值容差、fact-path 规则、回答覆盖率定义和评分程序。旧的 6 案例/25 事实记录仅作为历史开发基线，不作为本研究当前共同任务结果。

2.10 相近工具入口与独立数据基准

为进行设计层面的入口核对，在独立临时 R 库中安装 iSEE 2.14.0、GPTCelltype 1.0.1 和 ellmer 0.5.0；另将 btw 列为候选工具，但不把未完成的安装尝试作为性能比较。iSEE 测试预先指定真实 PBMC3k SCE、已有 UMAP 和 `mito_qc` 变量，并由 Playwright 检查 DOM 属性和图像加载。GPTCelltype 测试从真实 PBMC3k counts 派生 3 个 cluster 和 30 行 marker 表，检查提示构建；不提供在线 API key。ellmer 与 BioExplainR 通过本地 OpenAI-compatible replay 服务重放 6 个保存 prompt，比较客户端响应文本。上述设计评价入口兼容性和传输解析，不评价细胞类型准确率、模型质量或工具优劣。

为提供未参与 airway/PBMC3k 开发的数值基准，使用 pasilla 1.30.0 数据归档，按 DESeq2 1.42.0 的 `~ type + condition` 设计比较 treated 与 untreated。预设 P_{adj} 阈值 0.01、0.05、0.10 和 |log2FC| 阈值 0、1，逐项比较 BioExplainR 从真实 DESeqResults 提取的特征数、显著数、上下调数和缺失校正值与直接源表计算值，共 6 个阈值组合、30 个事实。数据归档 SHA-256、计算脚本和逐项评分见补充表 S2-S3。

2.11 外部评分者评价设计

外部评分材料由 30 个去来源化解释案例组成，3 位评分者分别对每个案例的 8 个维度使用允许 0–2 分的量表：数字准确性、统计概念、生物学支持、可追溯性、不确定性、可读性、错误定位和语义保持。评分者只看到匿名解释和统一任务说明，不看到原始数据集、模型、方法或作者身份；本项目只保留聚合结果，不保留原始评分文件和个人评语。完全一致率定义为每个案例-维度中 3 位评分者分值相同的比例；相差不超过 1 分作为另一个描述性指标，不计算 ICC 或 kappa。

另设 30 个评分参与者的功能感知表，每人对 5 项功能给出 0–100 分，并选择“有用/没用”。该表没有任务正确率、完成时间、对照组、SUS、学习增益或信任校准终点，因此预先限定为描述性功能感知评价，而不是用户实验或教学效果研究。伦理、招募、同意和补偿信息在现有记录中不完整，结果只能在作者核实后用于投稿。

3 结果

3.1 软件与浏览器验证

在 R 4.3.3、Ubuntu 24.04 用户态环境中，testthat 的 525 项检查有 524 项通过、1 项因真实 DESeq2 类可用而跳过，失败与错误均为零；`R CMD check --no-manual --no-vignettes --no-build-vignettes` 为 `Status: OK`。浏览器自动化覆盖代码执行、DESeq2 解释、HTML 下载、PCA 渲染与回写、源核对、DeepSeek 页面调用、SCE/Seurat 选择、双连接工作区隔离及桌面/移动布局；各项自动断言通过，未记录 JavaScript 异常或失败资源请求（补充材料 S7）。

3.2 真实数据兼容性与对象摘要

airway 在 $P_{adj} < 0.05$、$|log2FC| > 1$ 时得到 999 个显著特征，其中上调 519 个、下调 480 个；5,204 个校正值缺失，17,165 个校正值非缺失，而原始 P 值均非缺失。只要求 $P_{adj} < 0.05$ 且非零效应时得到 4,030 个。适配器提取的目标事实与源表一致。PCA 的 PC1、PC2 分别解释 47.8429% 和 23.3834% 的方差（图 3）。在相同过滤和设计条件下，limma 和 edgeR 分别得到 1,301、1,292 个显著特征（表 3）。airway 在 $P_{adj} < 0.05$、$|log2FC| > 1$ 时得到 999 个显著特征，其中上调 519 个、下调 480 个；5,204 个校正值缺失，17,165 个校正值非缺失，而原始 P 值均非缺失。只要求 $P_{adj} < 0.05$ 且非零效应时得到 4,030 个。适配器提取的目标事实与源表一致。PCA 的 PC1、PC2 分别解释 47.8429% 和 23.3834% 的方差（图 3）。在相同过滤和设计条件下，limma 和 edgeR 分别得到 1,301、1,292 个显著特征（表 3）。

Reactome 的 1,104 项检验中有 1 项通过 BH 校正：Interleukin-4 and Interleukin-13 signaling（R-HSA-6785807），重叠 16 个基因，$P = 1.9558 \times 10^{-5}$，$P_{adj} = 0.02159$。PBMC3k 的 SCE 与 Seurat 对象均读取到 2,700 个细胞、32,738 个特征及单供体元数据，并可使用已有 UMAP 绘图（图 4）。新增的 ALL `ExpressionSet` 读取到 12,625 个特征和 128 个样本，按 BT 字段识别 10 个观察到的分组；

bladderbatch `ExpressionSet` 读取到 22,283 个特征和 57 个样本，识别 3 个癌症分组和 5 个批次。五个数据集的检查均为对象接入、确定性摘要或独立事实核对，不是跨数据集的生物学复现率或模型泛化性能。

在一条事实加证据响应中，五条显式数值声明和引用 ID 均通过核对；同一响应的自由文本包含“log2FC 似乎经过收缩（shrinkage）”的表述，而保存的分析流程未执行 `lfcShrink()`。原始措辞及定位见补充材料 S6。

3.3 事实摘要与证据消融

1,080 次主实验请求均成功并返回可解析结构化结果。有界原始输出匹配 437/1,440（30.35%），覆盖率为 35.83%，已回答准确率为 84.69%；两种 R 事实方法均为 1,440/1,440（100.0%），覆盖率与已回答准确率均为 100.0%（表 2、图 2）。有界基线的低覆盖率主要反映输入未提供完整事实：差异表达四项全表计数仅回答 9/360 项，generic 结构摘要目标没有回答；回答的显著数值整体较准确。六类功能家族结果见表 4，480 个目标及方法别的逐项匹配次数见表 8。

3.4 独立数据与相近工具入口

pasilla 的独立数据基准包含 14,599 个特征和 7 个文库。6 个阈值组合的 30 个特征、显著、上下调和缺失校正值比较全部通过；在 $P_{adj} < 0.05$ 且 $|\log2FC| > 1$ 时，218 个特征显著，其中上调 108 个、下调 110 个，5,800 个校正值缺失（补充图 S2、表 S2-S3）。ALL 与 bladderbatch 的 `ExpressionSet` 摘要分别通过 12,625 × 128 和 22,283 × 57 的对象/设计字段检查；完整版本、归档 SHA-256 和逐数据集状态见补充材料 S1 及 `research/results/public_datasets/`。

iSEE 的真实 `SingleCellExperiment` 入口初始化和浏览器图形检查通过；GPTCelltype 的真实 marker 到提示构建通过；ellmer 与 BioExplainR 的保存响应 replay 共 12/12 次保持文本一致。btw 未安装。因为这些任务不同于 BioExplainR 的完整解释任务，结果只作为工作流兼容性记录，不构成性能排名或优劣结论。

有界原始输出的三轮匹配数为 149/480、143/480、145/480；R 事实摘要和 R 事实加证据每轮均为 480/480。各轮共享相同案例和目标，因此轮间波动只作描述性报告，不作为独立数据集推断。

事实加证据的 `evidence_used` 中引用 ID 共出现 18 次，均来自给定集合；事实方法未提供证据时为零。原始基线给出 45 个输入未提供的引用字符串，均记为未知引用，其中包括非文献式标识（补充表 S1）。

三种方法的中位响应时间分别为 2.230 s、2.680 s、2.905 s（表 2）；提示输入分别使用 190,305、445,731、498,651 tokens，输出分别为 167,277、203,194、223,801 tokens。按公开非缓存输入价 0.15 美元/百万 tokens 和输出价 0.60 美元/百万 tokens 作粗略估算，三种方法合计约 0.36 美元；该值不是账单，也未计入缓存折扣（补充表 S1）。

3.5 双模型与代码代理共同任务

在 120 个案例、480 个目标事实的统一评分下，StepFun `step-5-preview` 和 DeepSeek `deepseek-flash` 均回答 480/480 个目标且严格匹配 480/480（100%），覆盖率均为 100%（补充表 S4）。修正后的请求将 Facts JSON 序列化为 17 位并要求小数作为完整字符串复制；定向 PCA 测试和完整规模测试均

通过。StepFun 的最终请求关闭 `response_format = json_object`，以避免此前探针中的网关 JSON 格式不稳定。

3.6 外部评分者与功能感知评价

3 位外部评分者完成了 30 个匿名解释案例的全部 720 条评分；本批记录只出现 1 分和 2 分，没有 0 分记录。总体均值为 1.751/2；八个维度中，可追溯性均值最低（1.267），可读性和不确定性均值最高（均为 1.956）；数字准确性为 1.756，统计概念为 1.689，生物学支持为 1.733，错误定位为 1.933，语义保持为 1.722。案例-维度评分的完全一致率为 93.75%，相差不超过 1 分的比例为 100%（表 7）。

30 位评分参与者完成了 5 项功能的 150 条功能感知评分。总体平均分为 91.98/100，144/150（96.0%）标记为有用。五项功能平均分分别为：运行并记录 R 代码 91.57，解释 R 生物信息学对象 91.00，生成常用分析图形 93.03，证据与来源追踪 91.23，生成分析报告 93.07。证据与来源追踪的有用比例为 90.0%，其余功能为 93.3%-100.0%（表 7）。

3.7 声明、图形与修复的机制挑战

验证器将四类注入显式错误全部判为 `fail`（72/72），仅路径无值声明均为 `partial`（18/18），移除验证器时全部为 `unchecked`（表 5）。六种图形错误全部被判为 `fail`，三张正确图全部为 `pass`（表 6）。保持和反转参考水平的代码都可执行，但只有保持 `untrt` 参考水平的方案通过指定不变量。

4 相关工具的设计比较

表 1 将对象接入、确定性事实、证据、声明验证、图形核对、错误诊断与语言入口合并为一张设计比较表。信息依据论文、官方文档或项目页，截至 2026-10-04；符号表示已描述的核心能力、部分或任务依赖能力，以及未见本文式内置机制。除 BioExplainR 外，工具未在共同任务上实际运行；空缺不表示无法扩展，也不表示性能较差。

BioExplainR 的定位是已有 R 结果的解释与检查层。与细胞标注工具相比，其核心输出不是细胞标签；与通用代码执行代理相比，其自主分析范围更有限；与 iSEE 相比，其探索组件更基础。可比较的贡献是把对象来源、R 事实、结构化声明、源图形与修复条件连接到同一报告，而不是一种新的差异表达算法。相对工具的实际收益需要定义共同任务后另行评价。

5 讨论

5.1 系统边界

BioExplainR 不能修正有缺陷的实验设计、批次混杂、生物学重复不足、缺乏支持的文献论断或所有形式的图形误读。它不能替代统计学家或领域专家，不能自动执行模型生成的代码，也不能把细胞层面的观测变成充分的生物学重复；用户提交的修复代码仍需显式运行并检查不变量。单细胞流程把细胞作为观测对象进行摘要，但不把细胞当作独立生物学重复。外部评分者和功能感知评分提供了描述性可接受性信息，但不能替代独立实验设计审查或真实用户对照研究。

5.2 为什么确定性事实重要

计数、方向和方差比例适合由程序精确计算。本轮结果与“先由 R 计算，再由模型组织”的设计一致：模型不必从有限预览猜测全表事实，也不承担长表逐行计算。本地模板使用同一摘要，事实来源不依赖在线模型成功。100% matching rate is a pipeline design target, not a model capability ceiling: all 480 target facts were computed by R from the full input and explicitly passed to the model as a bounded JSON summary. 因此该实验验证的是无损事实传递，不是模型独立推理、知识发现或摘要之外的自由文本正确性。

5.3 检索证据不等于论断支持

证据 ID 可追踪，使未知引用与给定记录可区分；但命中题名、已知数据库注释和文章支持某一论断不是同一层次。当前实验将证据的增量作用限制在闭集引用来源检查，且没有采用案例特异的证据集合。后续需要评价物种、组织、比较和结论级匹配，并经独立专家审读支持关系，不能把引用 ID 的通过率替代证据质量。

5.4 声明验证能够与不能够发现什么

显式声明验证可捕捉指定事实值、方向、路径和引用集合违例；修复不变量可区分“可运行”和“满足指定条件”。但本文的 shrinkage 负例显示，正确数值可与错误的自由文本并存。未声明数字、隐含因果、措辞过度概括和跨句矛盾可能不被发现。图形 pass 同样只表示检查到的映射与指定源对象一致，不能消除上游错误或所有视觉误导。因此，报告应分别展示事实、检查范围及未验证内容，而不是提供笼统的可靠性认证。

5.5 局限与后续研究

本研究是初步机制验证。扩展主实验和双模型共同任务均使用 120 个程序生成案例及相同的 480 个目标事实；案例数量和重复评分不等于独立生物学样本，也不构成对自然生物数据分布的泛化评估。`direct_bounded` 是刻意信息受限的基线，不能作为 BioExplainR 默认模型输入；默认工作流在 R 中分析完整对象，再传递完整确定性事实和有界 top-feature 预览。事实方法的 100% 匹配是输入已包含计算事实后的接口传递终点，不是自由文本或模型能力上限。外部评分与功能感知调查属于描述性、便利样本评价；它们不是随机对照试验，不包含任务准确率或完成时间，也不建立用户获益。它们与机制性消融分开报告，不能解释为学习增益或临床效用证据。pasilla 提供独立数值事实基准，但没有提供独立模型解释质量评估。软件兼容性仍只覆盖所测版本，图形检查范围有限，未验证完整上游版本矩阵。

面向 Bioinformatics Advances 或 BMC Bioinformatics 的下一步应先冻结版本、提示及评分规则，再增加未参与开发的数据、更多模型和多个代码代理，并在隔离沙箱中部署执行工具基线；相关工具需在共同任务上部署比较。下一轮用户研究应预注册任务正确标准、完成时间、信任校准和认知负荷，明确招募、伦理和同意流程，并采用目标用户群体进行对照评价。本文不据当前功能感知评分推断学习或用户收益。

6 结论

BioExplainR 为已有 R 生物信息学对象提供具有来源追踪与显式检查记录的解释层。其价值目前得到机制与工作流层面的支持；生物学解释质量和真实用户收益仍需独立验证。

数据、代码与稿件声明

软件可用性。 BioExplainR 0.3.1，MIT 许可证，要求 R >= 4.1.0，本研究使用 R 4.3.3。源代码、安装说明、示例、测试及复现脚本已保存在项目中。公开 GitHub URL：[待作者补齐]；版本化归档/Zenodo DOI：[待作者补齐]。本稿不将本地文件路径当作公开发布地址。

数据与补充材料。 airway/GSE52778、PBMC3k、pasilla、ALL 和 bladderbatch 均为公开数据；Reactome 使用带 SHA-256 的下载快照。120 个规模案例由可复现 R 脚本生成，完整 480 个目标及逐项主实验评分列于表 8 和 `research/results/main_scale_480/`。补充材料独立提供数据版本和五数据集测试（S1）、相近工具与 pasilla（S2）、主实验消融与原始记录（S3）、双模型规模共同任务（S3b）、预实验迭代（S4）、外部评分者与功能感知评价（S5）、语义负例（S6）、机制挑战和浏览器记录（S7）及投稿信息缺口（S8）。外部评分仅以聚合结果进入项目，不保存个人身份或原始评语文件。论文图表集中编排于附录，正文图 1-4、表 1-8、补充图 S1-S3 和补充表 S1-S5 均有 Word/Excel 与独立资产。

作者贡献。 [待作者按真实分工填写 CRediT：概念设计、方法学、软件、验证、正式分析、数据整理、写作、可视化、监督与经费获取；无需列入未承担的角色。]

利益冲突。 [待全体作者确认并填写。]

经费。 [待作者填写真实资助来源及编号；无资助时据实说明。]

伦理声明。 软件和生物信息学验证仅复用公开数据。本文新增的外部评分与功能感知评分来自外部填写表的聚合记录；当前交付记录不包含姓名、邮箱或其他直接身份信息，也没有保存招募方式、评分者/参与者资历、知情同意、补偿或伦理审批文件。作者在投稿前必须核实该评价是否属于需要伦理审查或豁免的研究，并补充真实的招募、知情同意、数据管理和审查信息；本文不虚构伦理审批编号，也不将这些聚合结果描述为已完成的正式用户实验。

AI 使用声明。 软件开发和稿件整理使用 AI 助手；解释实验使用用户授权的 DeepSeek API。本文实验数字来自保存的实际结果，AI 输出的统计与生物学解释不作为独立参考真值。署名作者负责审阅代码、原始响应、引用和全部结论。

通讯与作者信息。 姓名、单位、通讯邮箱：[待作者补齐]。

参考文献

以下采用顺序编码的 Vancouver 样式；期刊论文、预印本、软件文档、数据库快照和 GitHub 项目分别标注。文档/项目访问日期均为 2026-10-04。

1. Love MI, Huber W, Anders S. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. Genome Biol. 2014;15:550. doi: 10.1186/s13059-014-0550-8.

2. Ritchie ME, et al. limma powers differential expression analyses for RNA-sequencing and microarray studies. Nucleic Acids Res. 2015;43:e47. doi: 10.1093/nar/gkv007.

3. Robinson MD, McCarthy DJ, Smyth GK. edgeR: a Bioconductor package for differential expression analysis of digital gene expression data. Bioinformatics. 2010;26:139-140. doi: 10.1093/bioinformatics/btp616.

4. Huber W, et al. Orchestrating high-throughput genomic analysis with Bioconductor. Nat Methods. 2015;12:115-121. doi: 10.1038/nmeth.3252.

5. Amezquita RA, et al. Orchestrating single-cell analysis with Bioconductor. Nat Methods. 2020;17:137-145. doi: 10.1038/s41592-019-0654-x.

6. Hao Y, et al. Dictionary learning for integrative, multimodal and scalable single-cell analysis. Nat Biotechnol. 2024;42:293-304. doi: 10.1038/s41587-023-01767-y.

7. Wickham H. ggplot2: Elegant Graphics for Data Analysis. Cham: Springer; 2016. doi: 10.1007/978-3-319-24277-4. [专著]

8. Hou W, Ji Z. Assessing GPT-4 for cell type annotation in single-cell RNA-seq analysis. Nat Methods. 2024;21:1462-1465. doi: 10.1038/s41592-024-02235-4.

9. Nagarajan V, et al. SCassist: an AI based workflow assistant for single-cell analysis. Bioinformatics. 2025;41:btaf402. doi: 10.1093/bioinformatics/btaf402.

10. Wang Z, et al. GeneAgent: self-verification language agent for gene-set analysis using domain databases. Nat Methods. 2025;22:1677-1685. doi: 10.1038/s41592-025-02748-6.

11. Crowley G, Tabula Sapiens Consortium, Quake SR. Benchmarking cell type and gene set annotation by large language models with AnnDictionary. Nat Commun. 2025;16:9511. doi: 10.1038/s41467-025-64511-x.

12. Lobentanzer S, et al. A platform for the biomedical application of large language models. Nat Biotechnol. 2025;43:166-169. doi: 10.1038/s41587-024-02534-3.

13. Huang K, et al. Biomni: A General-Purpose Biomedical AI Agent. bioRxiv [预印本]. 2025. doi: 10.1101/2025.05.30.656746. 项目：https://github.com/snap-stanford/Biomni.

14. Su H, et al. BioMaster: Multi-agent system for automated bioinformatics analysis workflow. Patterns. 2026;7:101611. doi: 10.1016/j.patter.2026.101611.

15. Rue-Albrecht K, Marini F, Soneson C, Lun ATL. iSEE: Interactive SummarizedExperiment Explorer. F1000Res. 2018;7:741. doi: 10.12688/f1000research.14966.1.

16. Posit/tidyverse. ellmer: Chat with Large Language Models [软件文档]. https://ellmer.tidyverse.org/.

17. Zhu J, et al. Enhancing gene set overrepresentation analysis with large language models. Bioinformatics Advances. 2025;5:vbaf054. doi: 10.1093/bioadv/vbaf054. 项目：https://github.com/Alector-BIO/llm2geneset.

18. Xie E, et al. CASSIA: a multi-agent large language model for automated and interpretable cell annotation. Nat Commun. 2026;17:389. Published online 2025 Dec 7. doi: 10.1038/s41467-025-67084-x.

19. Wu Y, Tang F. scExtract: leveraging large language models for fully automated single-cell RNA-seq data annotation and prior-informed multi-dataset integration. Genome Biol. 2025;26:174. doi: 10.1186/s13059-025-03639-x.

20. Farquhar S, Kossen J, Kuhn L, Gal Y. Detecting hallucinations in large language models using semantic entropy. Nature. 2024;630:625-630. doi: 10.1038/s41586-024-07421-0.

21. Yu G, Wang LG, Han Y, He QY. clusterProfiler: an R package for comparing biological themes among gene clusters. OMICS. 2012;16:284-287. doi: 10.1089/omi.2011.0118.

22. Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. J R Stat Soc Series B. 1995;57:289-300. doi: 10.1111/j.2517-6161.1995.tb02031.x.

23. Bourgon R, Gentleman R, Huber W. Independent filtering increases detection power for high-throughput experiments. Proc Natl Acad Sci USA. 2010;107:9546-9551. doi: 10.1073/pnas.0914005107.

24. Europe PMC Consortium. Europe PMC: a full-text literature database for the life sciences and platform for innovation. Nucleic Acids Res. 2015;43:D1042-D1048. doi: 10.1093/nar/gku1061.

25. Binns D, et al. QuickGO: a web-based tool for Gene Ontology searching. Bioinformatics. 2009;25:3045-3046. doi: 10.1093/bioinformatics/btp536.

26. Gillespie M, et al. The Reactome pathway knowledgebase 2022. Nucleic Acids Res. 2022;50:D687-D692. doi: 10.1093/nar/gkab1028.

27. Kanehisa M, Goto S. KEGG: Kyoto Encyclopedia of Genes and Genomes. Nucleic Acids Res. 2000;28:27-30. doi: 10.1093/nar/28.1.27.

28. UniProt Consortium. UniProt: the Universal Protein Knowledgebase in 2023. Nucleic Acids Res. 2023;51:D523-D531. doi: 10.1093/nar/gkac1052.

29. Posit. Shiny for R [软件文档]. https://shiny.posit.co/r/.

30. Himes BE, et al. RNA-Seq transcriptome profiling identifies CRISPLD2 as a glucocorticoid responsive gene that modulates cytokine function in airway smooth muscle cells. PLoS One. 2014;9:e99625. doi: 10.1371/journal.pone.0099625. 数据包：https://bioconductor.org/packages/airway/.

31. Law CW, Chen Y, Shi W, Smyth GK. voom: precision weights unlock linear model analysis tools for RNA-seq read counts. Genome Biol. 2014;15:R29. doi: 10.1186/gb-2014-15-2-r29.

32. 10x Genomics. 3k PBMCs from a Healthy Donor, Chromium Single Cell Gene Expression v1.1.0 [公开数据集]. https://cf.10xgenomics.com/samples/cell-exp/1.1.0/pbmc3k/pbmc3k_filtered_gene_bc_matrices.tar.gz.

33. McInnes L, Healy J, Melville J. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. arXiv [预印本]. 2018;1802.03426. https://arxiv.org/abs/1802.03426.

34. Squair JW, et al. Confronting false discoveries in single-cell differential expression. Nat Commun. 2021;12:5692. doi: 10.1038/s41467-021-25960-2.

35. DeepSeek. Models & Pricing; Thinking Mode [服务文档]. https://api-docs.deepseek.com/quick_start/pricing; https://api-docs.deepseek.com/guides/thinking_mode.

36. Gallifant J, et al. The TRIPOD-LLM reporting guideline for studies using large language models. Nat Med. 2025;31:60-69. doi: 10.1038/s41591-024-03425-5.

37. Bioconductor. ALL: Acute Leukemia data package, version 1.44.0 [公开数据集]. https://bioconductor.org/packages/3.18/data/experiment/html/ALL.html. Archive SHA-256: `6c52471acf4bb77ed86e71c25e69ce5cc5235acec50785107b212934c6eec5db`.

38. Bioconductor. bladderbatch: Bladder Gene Expression Data Illustrating Batch Effects, version 1.40.0 [公开数据集]. https://bioconductor.org/packages/3.18/data/experiment/html/bladderbatch.html. Archive SHA-256: `74e7a300c2d2835f0dc82d70f9e90af55e7a5d248e7364a80b9e6bdd57dbafa5`.

附录 A：正文引用图表

图表在本稿中集中编排，编号沿用正文引用。每张图由相关子图组成；图内采用英文标签以便后续英文稿复用，每个 panel 同时保留独立 PDF/PNG/SVG 原件。图注与表注为中文。表格为可编辑 Word 表格，单独 Excel 保留相同展示内容及数值来源。

图 1 系统架构

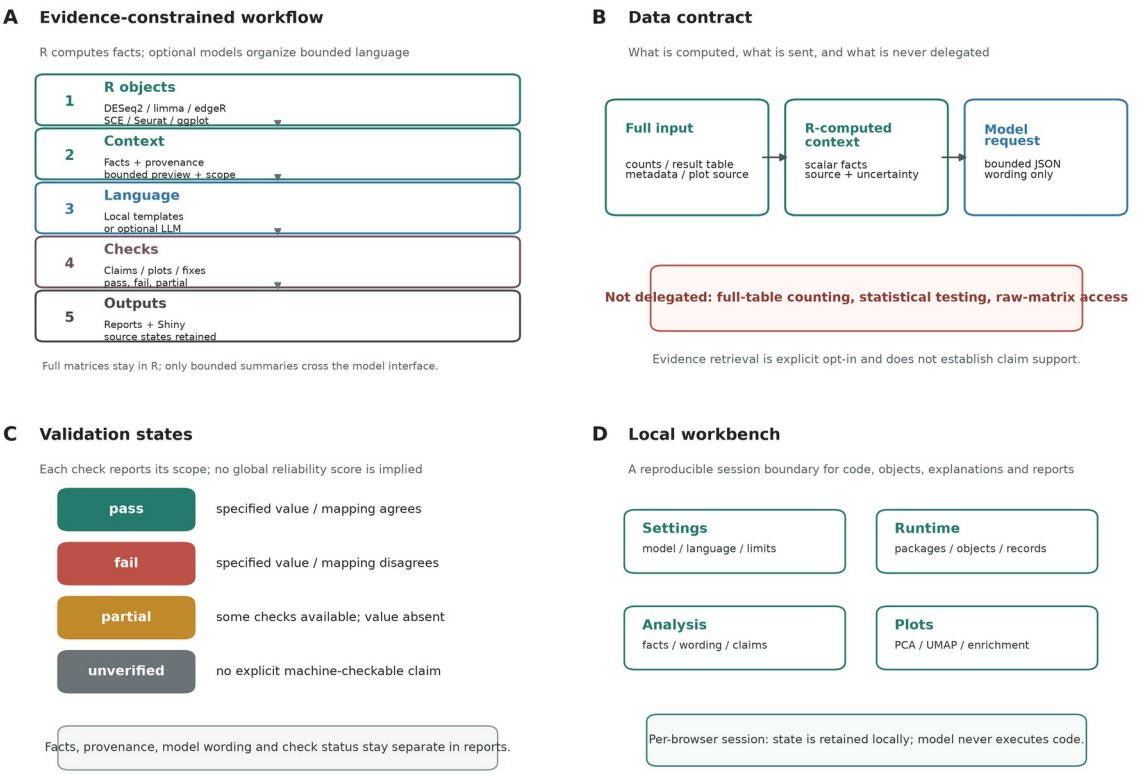


图 1. BioExplainR 的确定性事实、可选语言组织与分项验证架构。 (A) 从 R 分析对象到 `bio_context`、语言组织、检查和报告；(B) 输入、R-computed context 和 bounded model request 的数据契约；(C) `pass`、`fail`、`partial` 与 `unverified` 的检查状态；(D) 本地工作台的模型、运行记录、对象分析和图形工作流。适配器在 R 侧计算事实，有界摘要才可发送给模型；检查通过不等于自由文本或科学结论整体正确，证据命中也不等于论断支持。

图 2 目标事实匹配消融

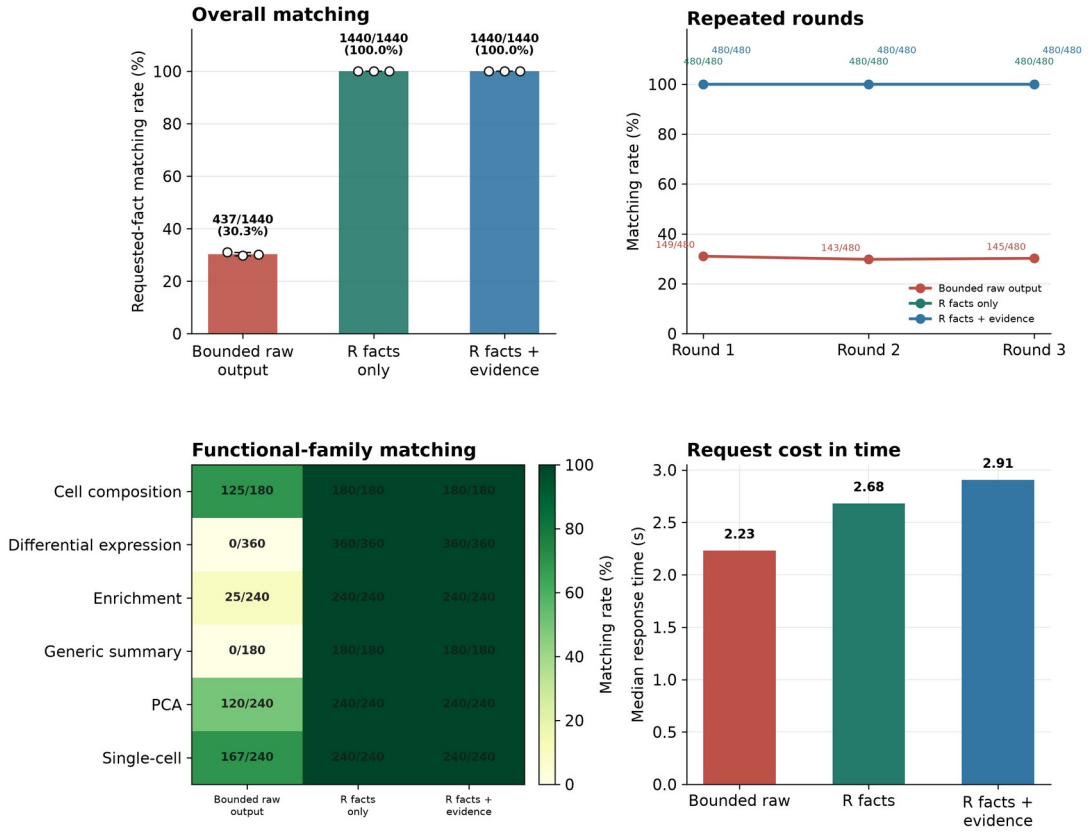


图 2. 120 个案例和 480 个目标事实的输入消融。 (A) 三轮总体匹配率及样本标准差；(B) 三轮匹配率轨迹，图内直接标注每轮分子/分母；(C) 六类功能家族匹配热图；(D) 请求中位响应时间。方法顺序为 bounded raw output、R facts only 和 R facts + evidence。有界原始输出 30.35% ± 0.12 个百分点，覆盖率 35.83%，已回答准确率 84.69%；两种事实方法均为 100.0% ± 0.0。每方法 360 次请求、1,440 条逐事实评分；重复共享案例和目标，误差棒不是置信区间。100% 是输入已包含 R 标量事实后的管道设计目标，不是模型能力上限或全文正确率。

图 3 airway PCA

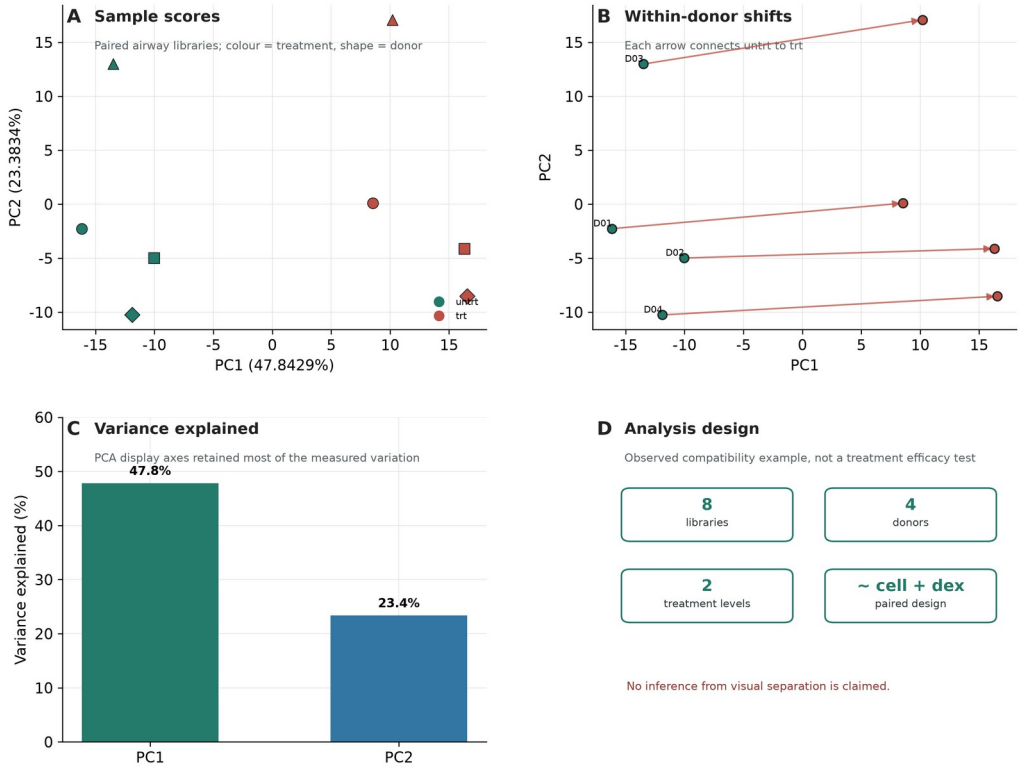


图 3. airway 配对 RNA-seq 的兼容性与设计边界。 (A) 样本文库得分，颜色为处理、点形为去来源化 donor code；(B) 每个 donor 内从 untrt 到 trt 的 PC1/PC2 位移；(C) PC1/PC2 方差解释率；(D) 文库、供体、处理和配对设计的范围。基于 VST 表达中的 500 个最高方差非恒定特征，中心化且不标准化；PC1 与 PC2 分别解释 47.8429% 和 23.3834% 的方差。共 8 个文库、4 个供体，而非 8 个独立供体。图用于真实对象与图形工作流展示，不将分离趋势视为额外假设检验。

图 4 PBMC3k UMAP

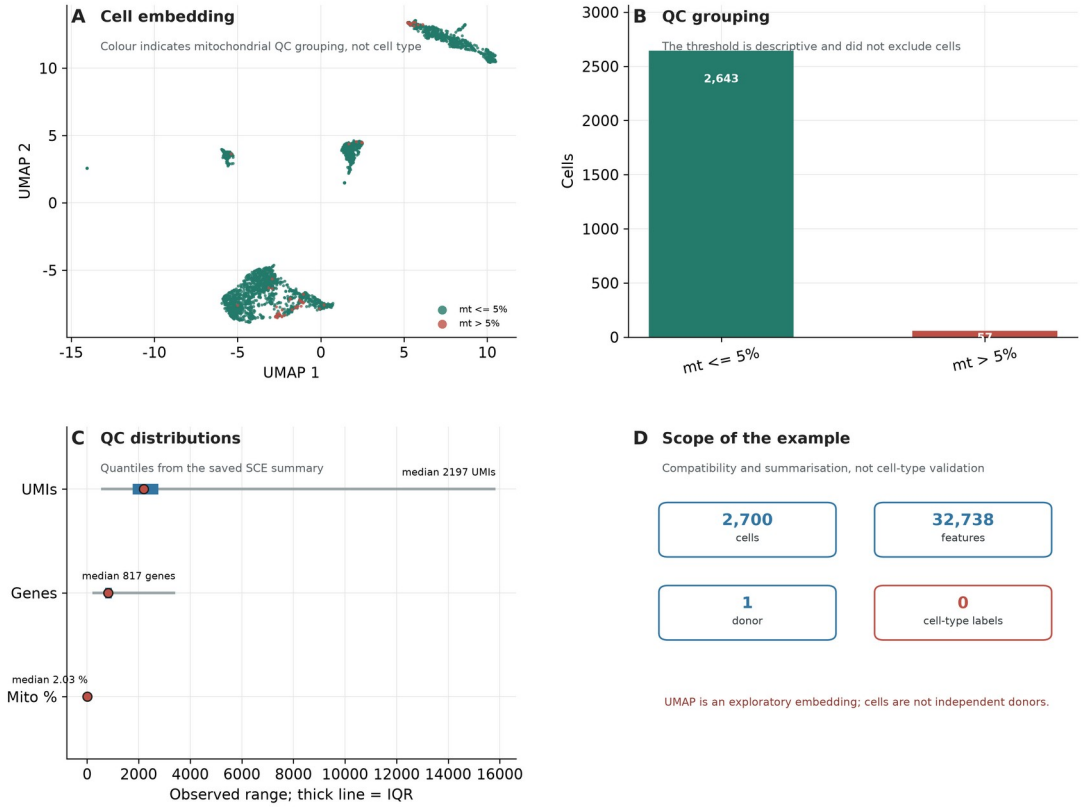


图 4. 单供体 PBMC3k 的嵌入、QC 和解释边界。 (A) 细胞嵌入，颜色表示线粒体比例 <= 5% 或 > 5% 的 QC 分组；(B) 两个 QC 分组的细胞数；(C) nCount、nFeature 和 percent.mt 的保存摘要分布；(D) 2,700 个细胞、32,738 个特征、单供体和不进行细胞类型验证的范围。使用 1,000 个最高方差 log-normalized 特征的 20 个主成分，由 uwot 生成嵌入；种子为 20261004，单线程。QC 颜色不是细胞类型标签；该阈值仅用于分组展示，未据此排除细胞。2,700 个细胞来自一个供体，不构成 2,700 个独立生物学重复。UMAP 不作为差异推断或注释准确率验证。

表 1 相关工具的对象接入、事实与检查能力比较

表 1. 相关工具的对象接入、事实与检查能力比较

Tool	Object parsing	R facts	Evidence	Claim check	Plot check	Error/fix	Language
GPTCelltype [8]	partial	×	partial	×	×	×	Model
SCassist [9]	partial	partial	partial	×	partial	partial	Model
GeneAgent [10]	partial	partial	✓	partial	×	partial	Model
AnnDictionary [11]	partial	×	partial	partial	×	×	Model
BioChatter [12]	partial	partial	✓	partial	partial	partial	Model
Biomni [13]	partial	partial	✓	partial	partial	partial	Model
BioMaster [14]	partial	partial	partial	partial	partial	partial	Model
iSEE [15]	✓	partial	×	×	partial	partial	Interface
ellmer [16]	×	×	partial	partial	×	×	Model
llm2geneset [17]	partial	partial	partial	×	×	×	Model
BioExplainR	✓	✓	✓	✓	✓	✓	English / optional Chinese

表注： 设计比较，不是性能排名。✓ 表示在定义范围内有文档描述的能力；partial 表示对象/任务受限、应用依赖或机制目标不同；× 表示未确认本文式内置机制，不表示不能扩展。Object parsing 指生信对象或特定输入结构接入；R facts 指可重复程序事实摘要；Evidence 指可追溯外部来源，不证明支持；Claim check 指生成内容的显式核对；Plot check 指源结果一致性；Error/fix 指执行追踪、诊断或修复支持。信息截至 2026-10-04，依据 [8-17]，比较工具没有共同任务实测。

来源： 论文参考文献 [8-17]；BioExplainR 0.3.1 源码和接口文档；人工设计编码，非运行评分

表 2 主实验结果

表 2. 三种输入方法的主实验结果

方法	正确/目标（匹配率）	覆盖率	已回答准确率	中位响应时间（s）
有界原始输出	437/1440（30.3%）	35.8%	84.7%	2.230
R 事实摘要	1440/1440（100.0%）	100.0%	100.0%	2.680
R 事实加证据	1440/1440（100.0%）	100.0%	100.0%	2.905

表注： 每方法 120 案例 × 3 次调用 = 360 次请求，480 个目标重复三轮 = 1,440 条评分；三方法共 1,080 次请求、4,320 条评分。覆盖率为非 null 标量数/目标数，已回答准确率为正确数/已回答数；有界原始输出匹配 437/1,440、覆盖率 35.83%、已回答准确率 84.69%；两种事实方法均为 1,440/1,440。100% 是已提供 R 标量事实后的管道设计目标，不是模型能力上限、自由文本正确率或外部泛化性能。时间为 API 请求耗时的中位数，不含上游分析、数据下载或证据检索。

来源： research/results/main_scale_480/ablation_summary.csv；fact_scores.csv；model_calls.csv

表 3 实际对象兼容性

表 3. 所测真实对象与版本的兼容性

对象/软件版本	输入	摘要/绘图观察	解释边界
DESeqResults / DESeq2 1.42.0	airway 配对	22,369 特征；显著 999（519 上、480 下）	完整结果计数；未经 LFC shrinkage
MArrayLM / limma 3.58.1	airway voom	系数 dextrt；显著 1,301	多系数需明确选择；与 DESeq2 不必相同
TopTags / edgeR 4.0.16	airway 准似然	完整 TopTags；显著 1,292	相同过滤/设计；统计模型不同
RangedSummarizedExperiment / 1.32.0	原始 airway	63,677 特征 × 8 文库	8 文库来自 4 供体；assay 诊断有界
SingleCellExperiment 1.24.0	PBMC3k	32,738 特征；2,700 细胞；QC/UMAP	单供体；稀疏诊断标记检查范围
Seurat / SeuratObject 5.0.1	同一 PBMC3k	2,700 细胞；Assay5；QC/UMAP	对象接入不是细胞类型标注验证
Biobase ExpressionSet / ALL 1.44.0	ALL	12,625 特征；128 样本；10 个 BT 分组	对象摘要；不推断差异设计
Biobase ExpressionSet / bladderbatch 1.40.0	bladderbatch	22,283 特征；57 样本；3 癌症组；5 批次	批次与分组摘要；不等于批次校正

表注： 差异表达筛选为 $P_{adj} < 0.05$ 且 $|log2FC| > 1$，采用各上游方法的结果；不同方法显著数不要求一致。此表仅描述实际安装版本与数据的成功观察，不是全部上游版本兼容矩阵，Seurat v4 未实际安装验证。SummarizedExperiment 的 Sample 列记录文库标识，供体数由 cell 元数据判断。ALL 与 bladderbatch 的 ExpressionSet 仅做对象、分组和批次摘要，不宣称完成差异表达或批次校正。

来源： research/results/compatibility.json；research/results/public_datasets/dataset_tests.csv；data_manifest.json；prepare_real_data.R；缓存中的真实对象

表 4 各案例目标事实评分

表 4. 六类功能家族的目标事实匹配数

案例	有界原始输出	R 事实摘要	R 事实加证据
Cell composition	125/180	180/180	180/180
Differential expression	0/360	360/360	360/360
Enrichment	25/240	240/240	240/240
Generic summary	0/180	180/180	180/180
PCA	120/240	240/240	240/240
Single-cell	167/240	240/240	240/240

表注： 每类分母为该功能家族的唯一目标数 × 3 次重复，不是生物学样本数；六类分别为 cell composition 60、differential expression 120、enrichment 80、generic 60、PCA 80、single-cell 80 个唯一目标，表中显示为三轮总计。完整逐项事实见表 8。

来源： research/results/main_scale_480/family_summary.csv；fact_scores.csv；case_manifest.csv

表 5 声明验证挑战

表 5. 显式声明验证的受控挑战

挑战类型	项数	启用验证器	移除验证器
错误数字	18	18 fail	unchecked
未知事实路径	18	18 fail	unchecked
向量冒充标量	18	18 fail	unchecked
未提供引用	18	18 fail	unchecked
仅路径、无数值	18	18 partial	unchecked

表注： 在 18 个事实加证据响应的上下文中逐类注入挑战。前四类 72 个显式错误全部 fail；最后 18 个仅路径无值声明均 partial，来自引用集合检查通过但事实值仍未验证。unchecked 指没有机器核对状态，不是通过。挑战衡量指定机制的识别能力，不是自然幻觉率或完整文本正确率。

来源： research/results/validation_ablation.csv；validation_summary.csv

表 6 图形与修复挑战

表 6. 图形来源核对与参考水平修复挑战

检查案例	期望状态	实际状态	移除检查器
正确火山图	pass	pass	unchecked
火山图方向反转	fail	fail	unchecked
原始 P 值替代校正值	fail	fail	unchecked
正确 PCA	pass	pass	unchecked
PCA 坐标改变	fail	fail	unchecked
PCA 方差轴标签改变	fail	fail	unchecked
正确富集图	pass	pass	unchecked
富集点大小改变	fail	fail	unchecked
富集点颜色改变	fail	fail	unchecked
保持 untrt 参考水平	invariants_passed	invariants_passed	unchecked
反转为 trt 参考水平	invariants_failed	invariants_failed	unchecked

表注： 前三类正确图共 3/3 pass，六种注入错误共 6/6 fail，均由保存的真实数据对象构造。修复两项均能执行，指定不变量为 8 行及 dex 水平顺序 untrt、trt；只有正确参考通过。unchecked 表示无对应检查状态；修复不检查不变量时最多报告运行成功，不能判定语义正确。本表不估计一般图形错误或修复成功率。

来源： research/results/plot_challenges.csv；plot_findings.json；fix_validation.json

表 7 外部评分者与功能感知评价

表 7. 外部评分者与功能感知评价

评价部分	项目	n	均值	标准差	比例	解释
外部评分者	biological_support	90	1.733	0.445		允许 0-2 分；本批无 0 分记录
外部评分者	error_localization	90	1.933	0.251		允许 0-2 分；本批无 0 分记录
外部评分者	numeric_accuracy	90	1.756	0.432		允许 0-2 分；本批无 0 分记录
外部评分者	readability	90	1.956	0.207		允许 0-2 分；本批无 0 分记录
外部评分者	semantic_preservation	90	1.722	0.450		允许 0-2 分；本批无 0 分记录
外部评分者	statistical_concepts	90	1.689	0.466		允许 0-2 分；本批无 0 分记录
外部评分者	traceability	90	1.267	0.445		允许 0-2 分；本批无 0 分记录
外部评分者	uncertainty	90	1.956	0.207		允许 0-2 分；本批无 0 分记录
外部评分者	总体 0-2 评分	720	1.751	0.433		3 人 × 30 案例 × 8 维度
外部评分者	case-dimension 一致性	240			93.8%	完全一致；相差不超过 1 分为 100%
功能感知	运行并记录 R 代码	30	91.57	4.88	100.0%	0-100 功能感知评分；1=有用，2=没用
功能感知	解释 R 生物信息学对象	30	91.00	5.87	93.3%	0-100 功能感知评分；1=有用，2=没用
功能感知	生成常用分析图形	30	93.03	4.47	100.0%	0-100 功能感知评分；1=有用，2=没用
功能感知	证据与来源追踪	30	91.23	7.78	90.0%	0-100 功能感知评分；1=有用，2=没用
功能感知	生成分析报告	30	93.07	4.71	96.7%	0-100 功能感知评分；1=有用，2=没用
功能感知	全部功能	150	91.98	5.67	96.0%	0-100 功能感知评分；1=有用，2=没用

表注： 3 位外部评分者对 30 个去来源化解释案例的 8 个维度进行 0-2 评分；30 位评分参与者对 5 项 BioExplainR 功能进行 0-100 功能感知评分并判断是否有用。所有记录均来自外部填写表，无缺失。结果是描述性外部评价，不是随机对照实验、SUS、学习增益或临床效用评价。

来源： research/results/human_evaluation/expert_dimension_summary.csv；user_feature_summary.csv；expert_agreement_summary.csv；human_evaluation_manifest.json

表 8 480 个目标事实逐项主实验结果

表 8. 480 个目标事实的逐项主实验结果

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
cell_composition_001	cell_composition	n_cells_used	95	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_001	cell_composition	n_clusters	3	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_001	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3
cell_composition_001	cell_composition	n_samples	5	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_002	cell_composition	n_cells_used	120	2/3	2/3	3/3	3/3	3/3	3/3
cell_composition_002	cell_composition	n_clusters	4	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_002	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3
cell_composition_002	cell_composition	n_samples	6	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_003	cell_composition	n_cells_used	147	2/3	2/3	3/3	3/3	3/3	3/3
cell_composition_003	cell_composition	n_clusters	2	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_003	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
cell_composition_003	cell_composition	n_samples	7	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_004	cell_composition	n_cells_used	88	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_004	cell_composition	n_clusters	3	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_004	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3
cell_composition_004	cell_composition	n_samples	4	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_005	cell_composition	n_cells_used	115	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_005	cell_composition	n_clusters	4	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_005	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3
cell_composition_005	cell_composition	n_samples	5	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_006	cell_composition	n_cells_used	144	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_006	cell_composition	n_clusters	2	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_006	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
cell_composition_006	cell_composition	n_samples	6	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_007	cell_composition	n_cells_used	175	2/3	2/3	3/3	3/3	3/3	3/3
cell_composition_007	cell_composition	n_clusters	3	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_007	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3
cell_composition_007	cell_composition	n_samples	7	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_008	cell_composition	n_cells_used	104	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_008	cell_composition	n_clusters	4	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_008	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3
cell_composition_008	cell_composition	n_samples	4	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_009	cell_composition	n_cells_used	135	1/3	1/3	3/3	3/3	3/3	3/3
cell_composition_009	cell_composition	n_clusters	2	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_009	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
cell_composition_009	cell_composition	n_samples	5	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_010	cell_composition	n_cells_used	168	2/3	2/3	3/3	3/3	3/3	3/3
cell_composition_010	cell_composition	n_clusters	3	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_010	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3
cell_composition_010	cell_composition	n_samples	6	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_011	cell_composition	n_cells_used	203	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_011	cell_composition	n_clusters	4	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_011	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3
cell_composition_011	cell_composition	n_samples	7	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_012	cell_composition	n_cells_used	120	1/3	1/3	3/3	3/3	3/3	3/3
cell_composition_012	cell_composition	n_clusters	2	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_012	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
cell_composition_012	cell_composition	n_samples	4	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_013	cell_composition	n_cells_used	155	2/3	2/3	3/3	3/3	3/3	3/3
cell_composition_013	cell_composition	n_clusters	3	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_013	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3
cell_composition_013	cell_composition	n_samples	5	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_014	cell_composition	n_cells_used	192	2/3	2/3	3/3	3/3	3/3	3/3
cell_composition_014	cell_composition	n_clusters	4	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_014	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3
cell_composition_014	cell_composition	n_samples	6	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_015	cell_composition	n_cells_used	231	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_015	cell_composition	n_clusters	2	3/3	3/3	3/3	3/3	3/3	3/3
cell_composition_015	cell_composition	n_groups	2	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
cell_composition_015	cell_composition	n_samples	7	3/3	3/3	3/3	3/3	3/3	3/3
de_001	differential_expression	n_down	14	0/3	0/3	3/3	3/3	3/3	3/3
de_001	differential_expression	n_features	41	0/3	0/3	3/3	3/3	3/3	3/3
de_001	differential_expression	n_significant	28	0/3	0/3	3/3	3/3	3/3	3/3
de_001	differential_expression	n_up	14	0/3	0/3	3/3	3/3	3/3	3/3
de_002	differential_expression	n_down	14	0/3	0/3	3/3	3/3	3/3	3/3
de_002	differential_expression	n_features	42	0/3	0/3	3/3	3/3	3/3	3/3
de_002	differential_expression	n_significant	28	0/3	0/3	3/3	3/3	3/3	3/3
de_002	differential_expression	n_up	14	0/3	0/3	3/3	3/3	3/3	3/3
de_003	differential_expression	n_down	14	0/3	0/3	3/3	3/3	3/3	3/3
de_003	differential_expression	n_features	43	0/3	0/3	3/3	3/3	3/3	3/3
de_003	differential_expression	n_significant	29	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
de_003	differential_expression	n_up	15	0/3	0/3	3/3	3/3	3/3	3/3
de_004	differential_expression	n_down	15	0/3	0/3	3/3	3/3	3/3	3/3
de_004	differential_expression	n_features	44	0/3	0/3	3/3	3/3	3/3	3/3
de_004	differential_expression	n_significant	30	0/3	0/3	3/3	3/3	3/3	3/3
de_004	differential_expression	n_up	15	0/3	0/3	3/3	3/3	3/3	3/3
de_005	differential_expression	n_down	15	0/3	0/3	3/3	3/3	3/3	3/3
de_005	differential_expression	n_features	45	0/3	0/3	3/3	3/3	3/3	3/3
de_005	differential_expression	n_significant	30	0/3	0/3	3/3	3/3	3/3	3/3
de_005	differential_expression	n_up	15	0/3	0/3	3/3	3/3	3/3	3/3
de_006	differential_expression	n_down	15	0/3	0/3	3/3	3/3	3/3	3/3
de_006	differential_expression	n_features	46	0/3	0/3	3/3	3/3	3/3	3/3
de_006	differential_expression	n_significant	31	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
de_006	differential_expression	n_up	16	0/3	0/3	3/3	3/3	3/3	3/3
de_007	differential_expression	n_down	16	0/3	0/3	3/3	3/3	3/3	3/3
de_007	differential_expression	n_features	47	0/3	0/3	3/3	3/3	3/3	3/3
de_007	differential_expression	n_significant	32	0/3	0/3	3/3	3/3	3/3	3/3
de_007	differential_expression	n_up	16	0/3	0/3	3/3	3/3	3/3	3/3
de_008	differential_expression	n_down	16	0/3	0/3	3/3	3/3	3/3	3/3
de_008	differential_expression	n_features	48	0/3	0/3	3/3	3/3	3/3	3/3
de_008	differential_expression	n_significant	32	0/3	0/3	3/3	3/3	3/3	3/3
de_008	differential_expression	n_up	16	0/3	0/3	3/3	3/3	3/3	3/3
de_009	differential_expression	n_down	16	0/3	0/3	3/3	3/3	3/3	3/3
de_009	differential_expression	n_features	49	0/3	0/3	3/3	3/3	3/3	3/3
de_009	differential_expression	n_significant	33	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
de_009	differential_expression	n_up	17	0/3	0/3	3/3	3/3	3/3	3/3
de_010	differential_expression	n_down	17	0/3	0/3	3/3	3/3	3/3	3/3
de_010	differential_expression	n_features	50	0/3	0/3	3/3	3/3	3/3	3/3
de_010	differential_expression	n_significant	34	0/3	0/3	3/3	3/3	3/3	3/3
de_010	differential_expression	n_up	17	0/3	0/3	3/3	3/3	3/3	3/3
de_011	differential_expression	n_down	17	0/3	0/3	3/3	3/3	3/3	3/3
de_011	differential_expression	n_features	51	0/3	0/3	3/3	3/3	3/3	3/3
de_011	differential_expression	n_significant	34	0/3	0/3	3/3	3/3	3/3	3/3
de_011	differential_expression	n_up	17	0/3	0/3	3/3	3/3	3/3	3/3
de_012	differential_expression	n_down	17	0/3	0/3	3/3	3/3	3/3	3/3
de_012	differential_expression	n_features	52	0/3	0/3	3/3	3/3	3/3	3/3
de_012	differential_expression	n_significant	35	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
de_012	differential_expression	n_up	18	0/3	0/3	3/3	3/3	3/3	3/3
de_013	differential_expression	n_down	18	0/3	0/3	3/3	3/3	3/3	3/3
de_013	differential_expression	n_features	53	0/3	0/3	3/3	3/3	3/3	3/3
de_013	differential_expression	n_significant	36	0/3	0/3	3/3	3/3	3/3	3/3
de_013	differential_expression	n_up	18	0/3	0/3	3/3	3/3	3/3	3/3
de_014	differential_expression	n_down	18	0/3	1/3	3/3	3/3	3/3	3/3
de_014	differential_expression	n_features	54	0/3	0/3	3/3	3/3	3/3	3/3
de_014	differential_expression	n_significant	36	0/3	1/3	3/3	3/3	3/3	3/3
de_014	differential_expression	n_up	18	0/3	1/3	3/3	3/3	3/3	3/3
de_015	differential_expression	n_down	18	0/3	2/3	3/3	3/3	3/3	3/3
de_015	differential_expression	n_features	55	0/3	0/3	3/3	3/3	3/3	3/3
de_015	differential_expression	n_significant	37	0/3	2/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
de_015	differential_expression	n_up	19	0/3	2/3	3/3	3/3	3/3	3/3
de_016	differential_expression	n_down	19	0/3	0/3	3/3	3/3	3/3	3/3
de_016	differential_expression	n_features	56	0/3	0/3	3/3	3/3	3/3	3/3
de_016	differential_expression	n_significant	38	0/3	0/3	3/3	3/3	3/3	3/3
de_016	differential_expression	n_up	19	0/3	0/3	3/3	3/3	3/3	3/3
de_017	differential_expression	n_down	19	0/3	0/3	3/3	3/3	3/3	3/3
de_017	differential_expression	n_features	57	0/3	0/3	3/3	3/3	3/3	3/3
de_017	differential_expression	n_significant	38	0/3	0/3	3/3	3/3	3/3	3/3
de_017	differential_expression	n_up	19	0/3	0/3	3/3	3/3	3/3	3/3
de_018	differential_expression	n_down	19	0/3	0/3	3/3	3/3	3/3	3/3
de_018	differential_expression	n_features	58	0/3	0/3	3/3	3/3	3/3	3/3
de_018	differential_expression	n_significant	39	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
de_018	differential_expression	n_up	20	0/3	0/3	3/3	3/3	3/3	3/3
de_019	differential_expression	n_down	20	0/3	0/3	3/3	3/3	3/3	3/3
de_019	differential_expression	n_features	59	0/3	0/3	3/3	3/3	3/3	3/3
de_019	differential_expression	n_significant	40	0/3	0/3	3/3	3/3	3/3	3/3
de_019	differential_expression	n_up	20	0/3	0/3	3/3	3/3	3/3	3/3
de_020	differential_expression	n_down	20	0/3	0/3	3/3	3/3	3/3	3/3
de_020	differential_expression	n_features	60	0/3	0/3	3/3	3/3	3/3	3/3
de_020	differential_expression	n_significant	40	0/3	0/3	3/3	3/3	3/3	3/3
de_020	differential_expression	n_up	20	0/3	0/3	3/3	3/3	3/3	3/3
de_021	differential_expression	n_down	20	0/3	0/3	3/3	3/3	3/3	3/3
de_021	differential_expression	n_features	61	0/3	0/3	3/3	3/3	3/3	3/3
de_021	differential_expression	n_significant	41	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
de_021	differential_expression	n_up	21	0/3	0/3	3/3	3/3	3/3	3/3
de_022	differential_expression	n_down	21	0/3	0/3	3/3	3/3	3/3	3/3
de_022	differential_expression	n_features	62	0/3	0/3	3/3	3/3	3/3	3/3
de_022	differential_expression	n_significant	42	0/3	0/3	3/3	3/3	3/3	3/3
de_022	differential_expression	n_up	21	0/3	0/3	3/3	3/3	3/3	3/3
de_023	differential_expression	n_down	21	0/3	0/3	3/3	3/3	3/3	3/3
de_023	differential_expression	n_features	63	0/3	0/3	3/3	3/3	3/3	3/3
de_023	differential_expression	n_significant	42	0/3	0/3	3/3	3/3	3/3	3/3
de_023	differential_expression	n_up	21	0/3	0/3	3/3	3/3	3/3	3/3
de_024	differential_expression	n_down	21	0/3	0/3	3/3	3/3	3/3	3/3
de_024	differential_expression	n_features	64	0/3	0/3	3/3	3/3	3/3	3/3
de_024	differential_expression	n_significant	43	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
de_024	differential_expression	n_up	22	0/3	0/3	3/3	3/3	3/3	3/3
de_025	differential_expression	n_down	22	0/3	0/3	3/3	3/3	3/3	3/3
de_025	differential_expression	n_features	65	0/3	0/3	3/3	3/3	3/3	3/3
de_025	differential_expression	n_significant	44	0/3	0/3	3/3	3/3	3/3	3/3
de_025	differential_expression	n_up	22	0/3	0/3	3/3	3/3	3/3	3/3
de_026	differential_expression	n_down	22	0/3	0/3	3/3	3/3	3/3	3/3
de_026	differential_expression	n_features	66	0/3	0/3	3/3	3/3	3/3	3/3
de_026	differential_expression	n_significant	44	0/3	0/3	3/3	3/3	3/3	3/3
de_026	differential_expression	n_up	22	0/3	0/3	3/3	3/3	3/3	3/3
de_027	differential_expression	n_down	22	0/3	0/3	3/3	3/3	3/3	3/3
de_027	differential_expression	n_features	67	0/3	0/3	3/3	3/3	3/3	3/3
de_027	differential_expression	n_significant	45	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
de_027	differential_expression	n_up	23	0/3	0/3	3/3	3/3	3/3	3/3
de_028	differential_expression	n_down	23	0/3	0/3	3/3	3/3	3/3	3/3
de_028	differential_expression	n_features	68	0/3	0/3	3/3	3/3	3/3	3/3
de_028	differential_expression	n_significant	46	0/3	0/3	3/3	3/3	3/3	3/3
de_028	differential_expression	n_up	23	0/3	0/3	3/3	3/3	3/3	3/3
de_029	differential_expression	n_down	23	0/3	0/3	3/3	3/3	3/3	3/3
de_029	differential_expression	n_features	69	0/3	0/3	3/3	3/3	3/3	3/3
de_029	differential_expression	n_significant	46	0/3	0/3	3/3	3/3	3/3	3/3
de_029	differential_expression	n_up	23	0/3	0/3	3/3	3/3	3/3	3/3
de_030	differential_expression	n_down	23	0/3	0/3	3/3	3/3	3/3	3/3
de_030	differential_expression	n_features	70	0/3	0/3	3/3	3/3	3/3	3/3
de_030	differential_expression	n_significant	47	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
de_030	differential_expression	n_up	24	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_001	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_001	enrichment	n_significant	9	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_001	enrichment	n_terms	13	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_001	enrichment	significance_threshold	0.05	1/3	1/3	3/3	3/3	3/3	3/3
enrichment_002	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_002	enrichment	n_significant	8	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_002	enrichment	n_terms	14	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_002	enrichment	significance_threshold	0.05	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_003	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_003	enrichment	n_significant	7	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_003	enrichment	n_terms	15	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
enrichment_003	enrichment	significance_threshold	0.05	1/3	1/3	3/3	3/3	3/3	3/3
enrichment_004	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_004	enrichment	n_significant	13	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_004	enrichment	n_terms	16	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_004	enrichment	significance_threshold	0.05	3/3	3/3	3/3	3/3	3/3	3/3
enrichment_005	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_005	enrichment	n_significant	11	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_005	enrichment	n_terms	17	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_005	enrichment	significance_threshold	0.05	2/3	2/3	3/3	3/3	3/3	3/3
enrichment_006	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_006	enrichment	n_significant	11	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_006	enrichment	n_terms	18	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
enrichment_006	enrichment	significance_threshold	0.05	1/3	1/3	3/3	3/3	3/3	3/3
enrichment_007	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_007	enrichment	n_significant	11	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_007	enrichment	n_terms	19	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_007	enrichment	significance_threshold	0.05	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_008	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_008	enrichment	n_significant	16	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_008	enrichment	n_terms	20	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_008	enrichment	significance_threshold	0.05	1/3	1/3	3/3	3/3	3/3	3/3
enrichment_009	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_009	enrichment	n_significant	15	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_009	enrichment	n_terms	21	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
enrichment_009	enrichment	significance_threshold	0.05	1/3	1/3	3/3	3/3	3/3	3/3
enrichment_010	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_010	enrichment	n_significant	13	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_010	enrichment	n_terms	22	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_010	enrichment	significance_threshold	0.05	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_011	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_011	enrichment	n_significant	11	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_011	enrichment	n_terms	23	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_011	enrichment	significance_threshold	0.05	1/3	1/3	3/3	3/3	3/3	3/3
enrichment_012	enrichment	enrichment_method	ORA	1/3	1/3	3/3	3/3	3/3	3/3
enrichment_012	enrichment	n_significant	19	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_012	enrichment	n_terms	24	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
enrichment_012	enrichment	significance_threshold	0.05	2/3	2/3	3/3	3/3	3/3	3/3
enrichment_013	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_013	enrichment	n_significant	17	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_013	enrichment	n_terms	25	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_013	enrichment	significance_threshold	0.05	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_014	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_014	enrichment	n_significant	15	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_014	enrichment	n_terms	26	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_014	enrichment	significance_threshold	0.05	1/3	1/3	3/3	3/3	3/3	3/3
enrichment_015	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_015	enrichment	n_significant	15	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_015	enrichment	n_terms	27	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
enrichment_015	enrichment	significance_threshold	0.05	1/3	1/3	3/3	3/3	3/3	3/3
enrichment_016	enrichment	enrichment_method	ORA	2/3	2/3	3/3	3/3	3/3	3/3
enrichment_016	enrichment	n_significant	23	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_016	enrichment	n_terms	28	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_016	enrichment	significance_threshold	0.05	3/3	3/3	3/3	3/3	3/3	3/3
enrichment_017	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_017	enrichment	n_significant	19	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_017	enrichment	n_terms	29	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_017	enrichment	significance_threshold	0.05	3/3	3/3	3/3	3/3	3/3	3/3
enrichment_018	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_018	enrichment	n_significant	18	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_018	enrichment	n_terms	30	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
enrichment_018	enrichment	significance_threshold	0.05	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_019	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_019	enrichment	n_significant	15	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_019	enrichment	n_terms	31	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_019	enrichment	significance_threshold	0.05	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_020	enrichment	enrichment_method	ORA	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_020	enrichment	n_significant	26	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_020	enrichment	n_terms	32	0/3	0/3	3/3	3/3	3/3	3/3
enrichment_020	enrichment	significance_threshold	0.05	1/3	1/3	3/3	3/3	3/3	3/3
generic_001	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_001	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_001	generic	size	1.2 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_001	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_002	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_002	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
generic_002	generic	size	1.4 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_002	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_003	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_003	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_003	generic	size	1.7 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_003	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_004	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_004	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_004	generic	size	1.9 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_004	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_005	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_005	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_005	generic	size	1.1 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_005	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_006	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_006	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_006	generic	size	1.3 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_006	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_007	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_007	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_007	generic	size	1.8 Kb	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
generic_007	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_008	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_008	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_008	generic	size	2 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_008	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_009	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_009	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_009	generic	size	2.3 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_009	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_010	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_010	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_010	generic	size	1.3 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_010	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_011	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_011	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_011	generic	size	1.6 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_011	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_012	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_012	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_012	generic	size	1.8 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_012	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
generic_013	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_013	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_013	generic	size	2 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_013	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_014	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_014	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_014	generic	size	2.3 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_014	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
generic_015	generic	class	data.frame	0/3	0/3	3/3	3/3	3/3	3/3
generic_015	generic	is_s4	FALSE	0/3	0/3	3/3	3/3	3/3	3/3
generic_015	generic	size	1.3 Kb	0/3	0/3	3/3	3/3	3/3	3/3
generic_015	generic	type	list	0/3	0/3	3/3	3/3	3/3	3/3
pca_001	pca	n_observations	9	3/3	3/3	3/3	3/3	3/3	3/3
pca_001	pca	n_variables	13	3/3	3/3	3/3	3/3	3/3	3/3
pca_001	pca	variance_explained.1	0.271270133685751	0/3	1/3	3/3	3/3	3/3	3/3
pca_001	pca	variance_explained.2	0.249717355808251	0/3	1/3	3/3	3/3	3/3	3/3
pca_002	pca	n_observations	10	3/3	3/3	3/3	3/3	3/3	3/3
pca_002	pca	n_variables	14	3/3	3/3	3/3	3/3	3/3	3/3
pca_002	pca	variance_explained.1	0.277259874701818	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
pca_002	pca	variance_explained.2	0.172528149555537	0/3	0/3	3/3	3/3	3/3	3/3
pca_003	pca	n_observations	11	3/3	3/3	3/3	3/3	3/3	3/3
pca_003	pca	n_variables	15	3/3	3/3	3/3	3/3	3/3	3/3
pca_003	pca	variance_explained.1	0.260781512201158	0/3	3/3	3/3	3/3	3/3	3/3
pca_003	pca	variance_explained.2	0.166246019013179	0/3	3/3	3/3	3/3	3/3	3/3
pca_004	pca	n_observations	12	3/3	3/3	3/3	3/3	3/3	3/3
pca_004	pca	n_variables	16	3/3	3/3	3/3	3/3	3/3	3/3
pca_004	pca	variance_explained.1	0.245121217215335	0/3	3/3	3/3	3/3	3/3	3/3
pca_004	pca	variance_explained.2	0.201113866170813	0/3	3/3	3/3	3/3	3/3	3/3
pca_005	pca	n_observations	8	3/3	3/3	3/3	3/3	3/3	3/3
pca_005	pca	n_variables	17	3/3	3/3	3/3	3/3	3/3	3/3
pca_005	pca	variance_explained.1	0.296289717608507	0/3	0/3	3/3	3/3	3/3	3/3
pca_005	pca	variance_explained.2	0.222088758537468	0/3	0/3	3/3	3/3	3/3	3/3
pca_006	pca	n_observations	9	3/3	3/3	3/3	3/3	3/3	3/3
pca_006	pca	n_variables	18	3/3	3/3	3/3	3/3	3/3	3/3
pca_006	pca	variance_explained.1	0.283722090405908	0/3	2/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
pca_006	pca	variance_explained.2	0.206097381041989	0/3	2/3	3/3	3/3	3/3	3/3
pca_007	pca	n_observations	10	3/3	3/3	3/3	3/3	3/3	3/3
pca_007	pca	n_variables	19	3/3	3/3	3/3	3/3	3/3	3/3
pca_007	pca	variance_explained.1	0.244422709480074	0/3	0/3	3/3	3/3	3/3	3/3
pca_007	pca	variance_explained.2	0.226476774551318	0/3	0/3	3/3	3/3	3/3	3/3
pca_008	pca	n_observations	11	3/3	3/3	3/3	3/3	3/3	3/3
pca_008	pca	n_variables	20	3/3	3/3	3/3	3/3	3/3	3/3
pca_008	pca	variance_explained.1	0.252880016830299	0/3	3/3	3/3	3/3	3/3	3/3
pca_008	pca	variance_explained.2	0.206099902816845	0/3	3/3	3/3	3/3	3/3	3/3
pca_009	pca	n_observations	12	3/3	3/3	3/3	3/3	3/3	3/3
pca_009	pca	n_variables	21	3/3	3/3	3/3	3/3	3/3	3/3
pca_009	pca	variance_explained.1	0.200122869533719	0/3	1/3	3/3	3/3	3/3	3/3
pca_009	pca	variance_explained.2	0.155485671133068	0/3	1/3	3/3	3/3	3/3	3/3
pca_010	pca	n_observations	8	3/3	3/3	3/3	3/3	3/3	3/3
pca_010	pca	n_variables	22	3/3	3/3	3/3	3/3	3/3	3/3
pca_010	pca	variance_explained.1	0.314617546033524	0/3	0/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
pca_010	pca	variance_explained.2	0.211552620625017	0/3	0/3	3/3	3/3	3/3	3/3
pca_011	pca	n_observations	9	3/3	3/3	3/3	3/3	3/3	3/3
pca_011	pca	n_variables	23	3/3	3/3	3/3	3/3	3/3	3/3
pca_011	pca	variance_explained.1	0.230697768815697	0/3	0/3	3/3	3/3	3/3	3/3
pca_011	pca	variance_explained.2	0.212040347771989	0/3	0/3	3/3	3/3	3/3	3/3
pca_012	pca	n_observations	10	3/3	3/3	3/3	3/3	3/3	3/3
pca_012	pca	n_variables	24	3/3	3/3	3/3	3/3	3/3	3/3
pca_012	pca	variance_explained.1	0.224922549194911	0/3	0/3	3/3	3/3	3/3	3/3
pca_012	pca	variance_explained.2	0.188467356844414	0/3	0/3	3/3	3/3	3/3	3/3
pca_013	pca	n_observations	11	3/3	3/3	3/3	3/3	3/3	3/3
pca_013	pca	n_variables	25	3/3	3/3	3/3	3/3	3/3	3/3
pca_013	pca	variance_explained.1	0.227965316647256	0/3	1/3	3/3	3/3	3/3	3/3
pca_013	pca	variance_explained.2	0.201087337167717	0/3	1/3	3/3	3/3	3/3	3/3
pca_014	pca	n_observations	12	3/3	3/3	3/3	3/3	3/3	3/3
pca_014	pca	n_variables	26	3/3	3/3	3/3	3/3	3/3	3/3
pca_014	pca	variance_explained.1	0.238807096808874	0/3	1/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
pca_014	pca	variance_explained.2	0.155516026971229	0/3	1/3	3/3	3/3	3/3	3/3
pca_015	pca	n_observations	8	3/3	3/3	3/3	3/3	3/3	3/3
pca_015	pca	n_variables	27	3/3	3/3	3/3	3/3	3/3	3/3
pca_015	pca	variance_explained.1	0.287267658668306	0/3	0/3	3/3	3/3	3/3	3/3
pca_015	pca	variance_explained.2	0.245318405729936	0/3	0/3	3/3	3/3	3/3	3/3
pca_016	pca	n_observations	9	3/3	3/3	3/3	3/3	3/3	3/3
pca_016	pca	n_variables	28	3/3	3/3	3/3	3/3	3/3	3/3
pca_016	pca	variance_explained.1	0.235405205041443	0/3	0/3	3/3	3/3	3/3	3/3
pca_016	pca	variance_explained.2	0.198673977498071	0/3	0/3	3/3	3/3	3/3	3/3
pca_017	pca	n_observations	10	3/3	3/3	3/3	3/3	3/3	3/3
pca_017	pca	n_variables	29	3/3	3/3	3/3	3/3	3/3	3/3
pca_017	pca	variance_explained.1	0.219557783770627	0/3	0/3	3/3	3/3	3/3	3/3
pca_017	pca	variance_explained.2	0.174545355498716	0/3	0/3	3/3	3/3	3/3	3/3
pca_018	pca	n_observations	11	3/3	3/3	3/3	3/3	3/3	3/3
pca_018	pca	n_variables	30	3/3	3/3	3/3	3/3	3/3	3/3
pca_018	pca	variance_explained.1	0.215693523722486	0/3	1/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
pca_018	pca	variance_explained.2	0.157202319010703	0/3	1/3	3/3	3/3	3/3	3/3
pca_019	pca	n_observations	12	3/3	3/3	3/3	3/3	3/3	3/3
pca_019	pca	n_variables	31	3/3	3/3	3/3	3/3	3/3	3/3
pca_019	pca	variance_explained.1	0.177623213936533	0/3	3/3	3/3	3/3	3/3	3/3
pca_019	pca	variance_explained.2	0.157195177500665	0/3	3/3	3/3	3/3	3/3	3/3
pca_020	pca	n_observations	8	3/3	3/3	3/3	3/3	3/3	3/3
pca_020	pca	n_variables	32	3/3	3/3	3/3	3/3	3/3	3/3
pca_020	pca	variance_explained.1	0.256680530473456	0/3	0/3	3/3	3/3	3/3	3/3
pca_020	pca	variance_explained.2	0.190745971758128	0/3	0/3	3/3	3/3	3/3	3/3
single_cell_001	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_001	single_cell	n_cells	32	2/3	3/3	3/3	3/3	3/3	3/3
single_cell_001	single_cell	n_features	26	2/3	3/3	3/3	3/3	3/3	3/3
single_cell_001	single_cell	n_samples	2	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_002	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_002	single_cell	n_cells	34	2/3	3/3	3/3	3/3	3/3	3/3
single_cell_002	single_cell	n_features	27	2/3	3/3	3/3	3/3	3/3	3/3
single_cell_002	single_cell	n_samples	3	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_003	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
single_cell_003	single_cell	n_cells	36	0/3	1/3	3/3	3/3	3/3	3/3
single_cell_003	single_cell	n_features	28	0/3	1/3	3/3	3/3	3/3	3/3
single_cell_003	single_cell	n_samples	1	2/3	2/3	3/3	3/3	3/3	3/3
single_cell_004	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_004	single_cell	n_cells	38	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_004	single_cell	n_features	29	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_004	single_cell	n_samples	2	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_005	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_005	single_cell	n_cells	40	1/3	3/3	3/3	3/3	3/3	3/3
single_cell_005	single_cell	n_features	30	1/3	3/3	3/3	3/3	3/3	3/3
single_cell_005	single_cell	n_samples	3	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_006	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_006	single_cell	n_cells	42	0/3	0/3	3/3	3/3	3/3	3/3
single_cell_006	single_cell	n_features	31	0/3	0/3	3/3	3/3	3/3	3/3
single_cell_006	single_cell	n_samples	1	0/3	0/3	3/3	3/3	3/3	3/3
single_cell_007	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_007	single_cell	n_cells	44	0/3	3/3	3/3	3/3	3/3	3/3
single_cell_007	single_cell	n_features	32	0/3	3/3	3/3	3/3	3/3	3/3
single_cell_007	single_cell	n_samples	2	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_008	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_008	single_cell	n_cells	46	3/3	3/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
single_cell_008	single_cell	n_features	33	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_008	single_cell	n_samples	3	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_009	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_009	single_cell	n_cells	48	2/3	2/3	3/3	3/3	3/3	3/3
single_cell_009	single_cell	n_features	34	2/3	2/3	3/3	3/3	3/3	3/3
single_cell_009	single_cell	n_samples	1	2/3	2/3	3/3	3/3	3/3	3/3
single_cell_010	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_010	single_cell	n_cells	50	0/3	2/3	3/3	3/3	3/3	3/3
single_cell_010	single_cell	n_features	35	0/3	2/3	3/3	3/3	3/3	3/3
single_cell_010	single_cell	n_samples	2	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_011	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_011	single_cell	n_cells	52	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_011	single_cell	n_features	36	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_011	single_cell	n_samples	3	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_012	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_012	single_cell	n_cells	54	2/3	2/3	3/3	3/3	3/3	3/3
single_cell_012	single_cell	n_features	37	2/3	2/3	3/3	3/3	3/3	3/3
single_cell_012	single_cell	n_samples	1	2/3	2/3	3/3	3/3	3/3	3/3
single_cell_013	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_013	single_cell	n_cells	56	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_013	single_cell	n_features	38	3/3	3/3	3/3	3/3	3/3	3/3

案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
single_cell_013	single_cell	n_samples	2	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_014	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_014	single_cell	n_cells	58	0/3	3/3	3/3	3/3	3/3	3/3
single_cell_014	single_cell	n_features	39	0/3	3/3	3/3	3/3	3/3	3/3
single_cell_014	single_cell	n_samples	3	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_015	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_015	single_cell	n_cells	60	2/3	2/3	3/3	3/3	3/3	3/3
single_cell_015	single_cell	n_features	40	2/3	2/3	3/3	3/3	3/3	3/3
single_cell_015	single_cell	n_samples	1	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_016	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_016	single_cell	n_cells	62	1/3	1/3	3/3	3/3	3/3	3/3
single_cell_016	single_cell	n_features	41	1/3	1/3	3/3	3/3	3/3	3/3
single_cell_016	single_cell	n_samples	2	2/3	2/3	3/3	3/3	3/3	3/3
single_cell_017	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_017	single_cell	n_cells	64	0/3	3/3	3/3	3/3	3/3	3/3
single_cell_017	single_cell	n_features	42	0/3	3/3	3/3	3/3	3/3	3/3
single_cell_017	single_cell	n_samples	3	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_018	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_018	single_cell	n_cells	66	0/3	0/3	3/3	3/3	3/3	3/3
single_cell_018	single_cell	n_features	43	0/3	0/3	3/3	3/3	3/3	3/3
single_cell_018	single_cell	n_samples	1	2/3	2/3	3/3	3/3	3/3	3/3

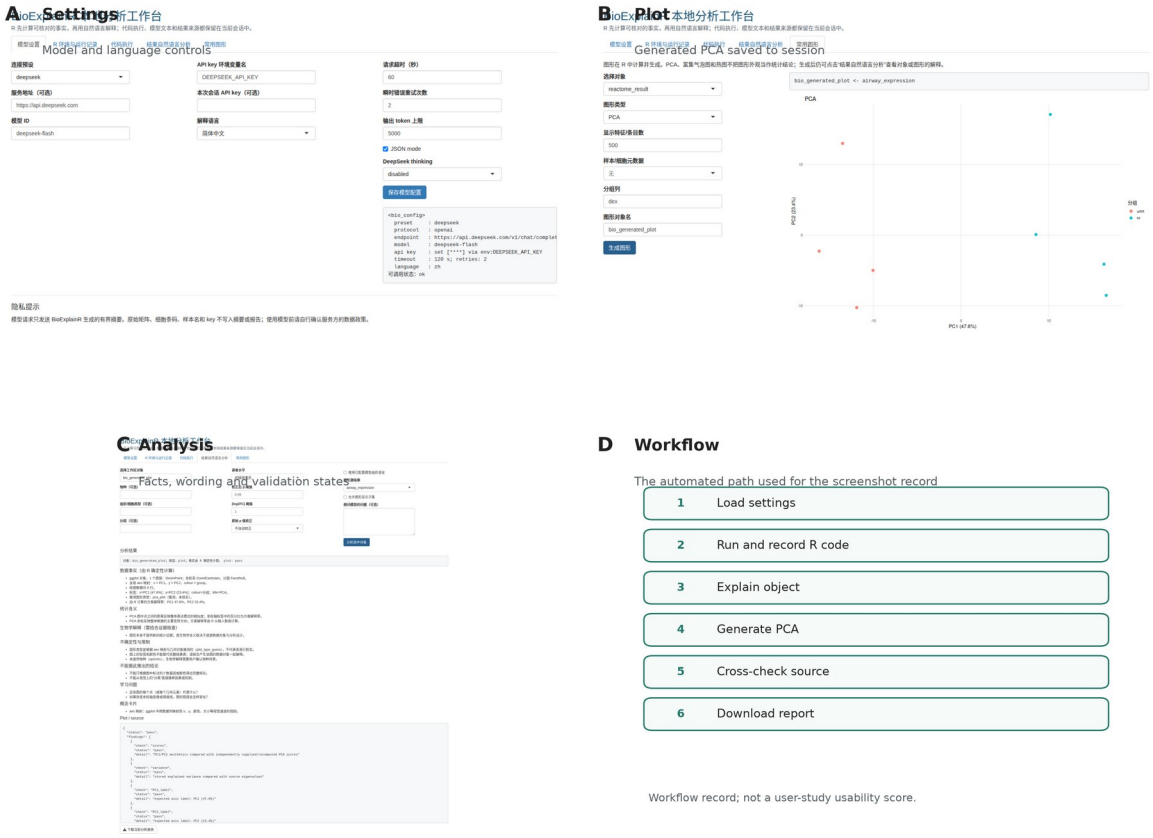
案例	功能家族	事实路径	R 参考值	有界原始匹配	有界原始回答	R 事实摘要匹配	R 事实摘要回答	R 事实加证据匹配	R 事实加证据回答
single_cell_019	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_019	single_cell	n_cells	68	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_019	single_cell	n_features	44	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_019	single_cell	n_samples	2	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_020	single_cell	assays	counts	3/3	3/3	3/3	3/3	3/3	3/3
single_cell_020	single_cell	n_cells	70	1/3	1/3	3/3	3/3	3/3	3/3
single_cell_020	single_cell	n_features	45	1/3	1/3	3/3	3/3	3/3	3/3
single_cell_020	single_cell	n_samples	3	2/3	2/3	3/3	3/3	3/3	3/3

表注： 本表列出 120 个可复现案例的 480 个唯一目标事实；每个方法实际重复 3 次。匹配和回答单元格为“次数/3”，分别表示严格 fact-path 与数值/字符串匹配次数、非空标量回答次数。该规模实验用于检验 BioExplainR 的输入契约、事实摘要和模型传递在不同对象家族下的稳定性；案例由包的确定性 adapter 从可复现对象生成，不是 480 个独立生物学样本，也不是模型泛化性能排名。

来源： research/results/main_scale_480/fact_scores.csv；reference_facts.json；case_manifest.csv；run_main_scale_experiment.R

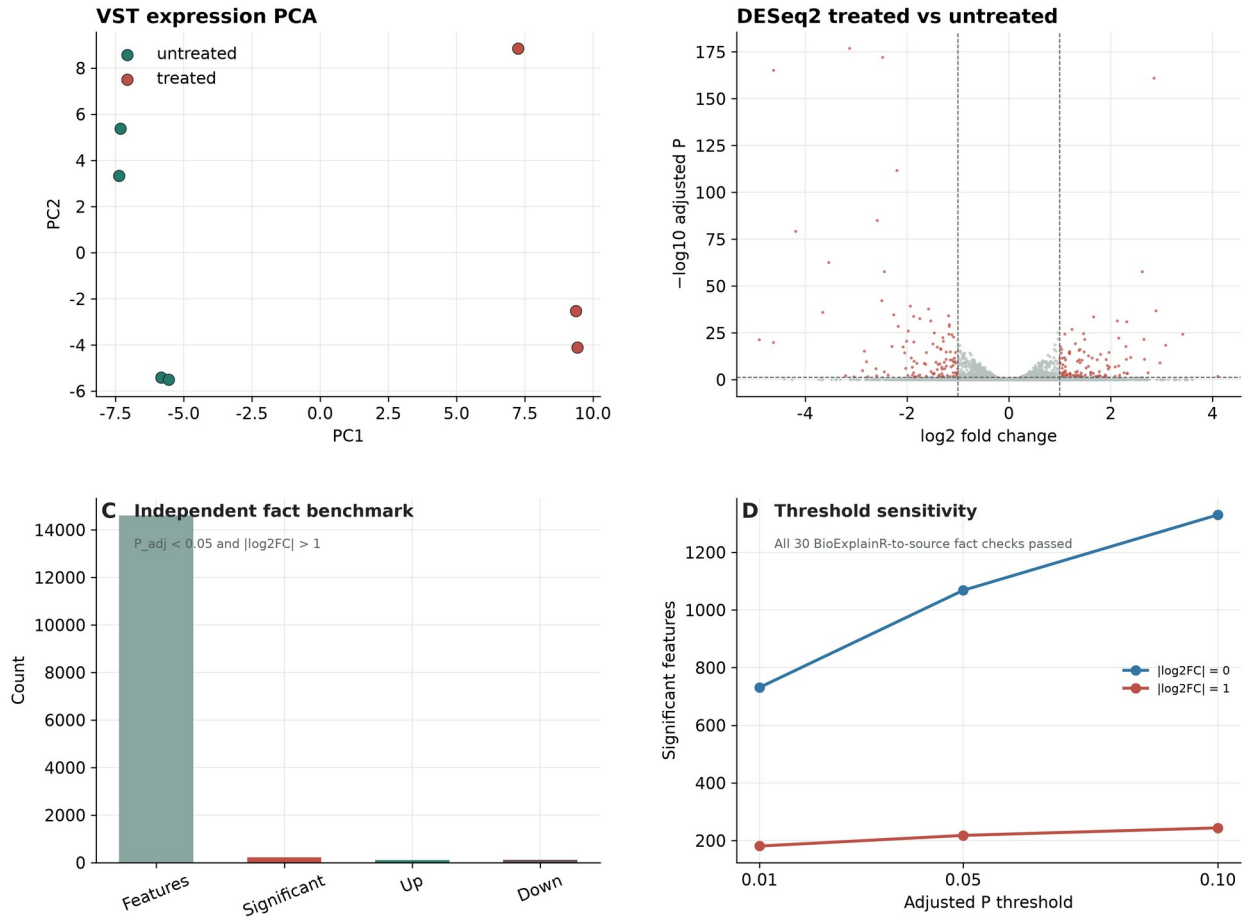
附录 B：补充图表与材料索引

补充图 S1 工作台记录



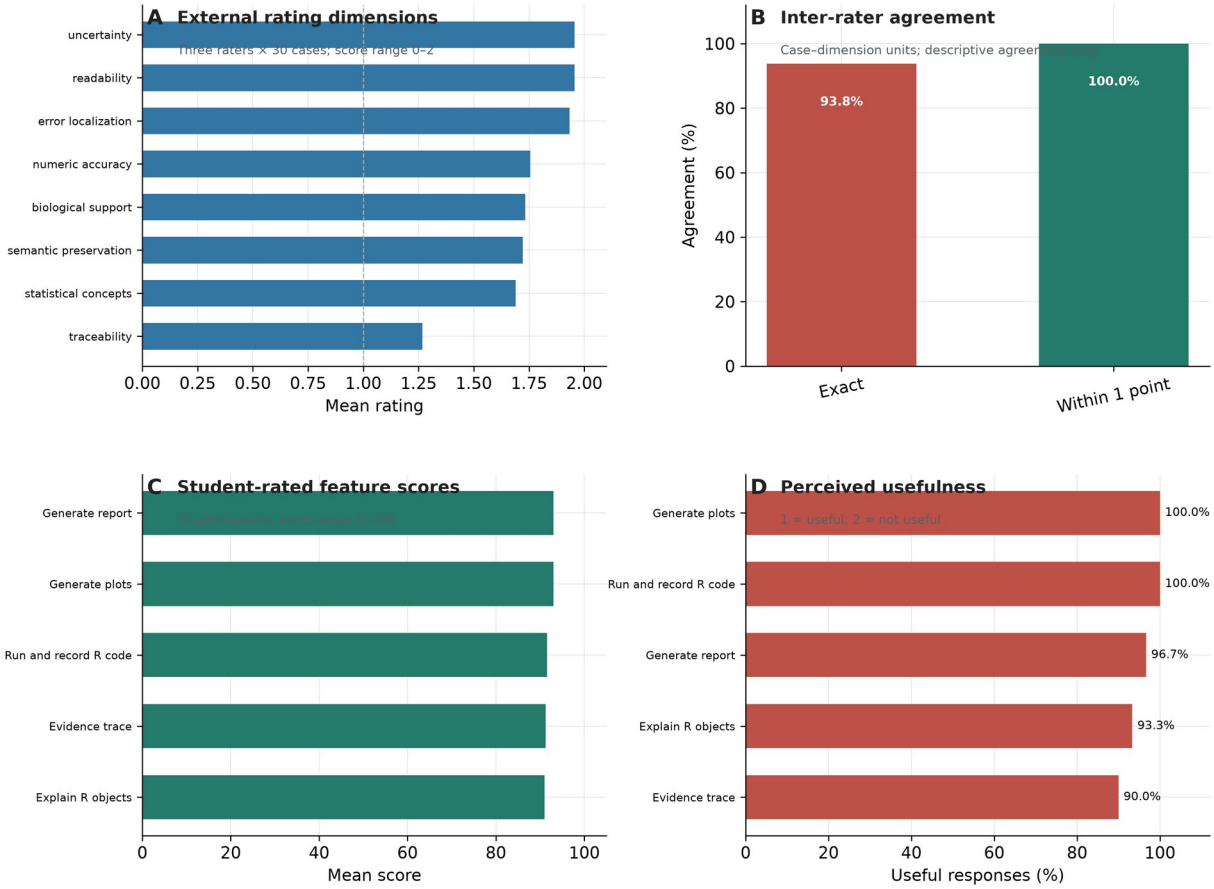
补充图 S1. 自动浏览器测试中的 Shiny 工作台记录。 (A) 模型设置和语言控制；(B) 图形生成与保存；(C) 对象分析、事实和验证状态；(D) 自动化步骤概览。详细步骤与断言见 `research/results/browser/summary.json`。图是工作流记录，不是用户研究、专家视觉评分或对所有页面可用性的认证。

补充图 S2 独立 pasilla 基准



补充图 S2. 独立 pasilla 基准。 (A) VST 表达 PCA；(B) DESeq2 treated vs untreated 火山图；(C) $P_{adj} < 0.05$ 且 $|log2FC| > 1$ 下的计数；(D) 阈值敏感性。图用于独立事实核对和工作流展示，不作为新的生物学结论。

补充图 S3 外部评分者与功能感知评价



补充图 S3. 外部评分者与功能感知评价的聚合结果。 (A) 外部评分维度；(B) case-dimension 一致性；(C) 功能评分；(D) 有用比例。图仅展示聚合描述统计，不替代正式用户研究。

补充表 S1 主实验 tokens 与估算成本

补充表 S1. 规模主实验 tokens 与估算成本

方法	引用 ID 次数	未知引用	输入 tokens	输出 tokens	估算 USD
有界原始输出	708	708	190305	167277	0.128912
R 事实摘要	0	0	445731	203194	0.188776
R 事实加证据	358	0	498651	223801	0.209078

表注： 规模主实验每种方法 360 次请求；tokens 来自保存的调用 usage。估算按非缓存输入 0.15 美元/百万 tokens、输出 0.60 美元/百万 tokens 计算，不是账单，也不包含历史预实验、浏览器或双模型共同任务；缓存折扣可能降低实际价格。

来源： research/results/main_scale_480/model_calls.csv；ablation_summary.csv；原始响应 usage

补充表 S2-S5

补充表 S2. 相近工具入口与独立数据基准

工具/组件	版本	实际任务	状态	保存证据
iSEE	2.14.0	真实 PBMC3k SCE 初始化、UMAP/QC 面板	pass	related_tool_tests.csv；iSEE_browser.json
GPTCelltype	1.0.1	真实 PBMC3k marker 表生成 3 个 cluster 的提示	pass	gptcelltype_prompt.json
ellmer	0.5.0	6 个保存 prompt 的本地 OpenAI-compatible replay；与 BioExplainR 各 6 次	pass（12/12）	transport_replay.csv
btw	未安装	安装尝试	not_installed	final_install_status.csv
BioExplainR + DESeq2	0.3.1 / 1.42.0	独立 pasilla counts、DESeq2 结果和事实提取	pass（30/30）	pasilla_test.json；pasilla_fact_checks.csv

表注： 这些是各工具自身入口或协议的实际兼容性测试，不是共同任务性能排名。GPTCelltype 未提供 API key，因此只评价真实 marker 输入到提示构建；ellmer 是保存响应的本地协议 replay，不是在线模型推理；btw 未安装，未纳入性能比较。

来源： research/results/related_tools/related_tool_tests.csv；transport_replay.csv；final_install_status.csv；pasilla_test.json；iSEE_browser.json

补充表 S3. pasilla 独立数据的阈值事实核对

P_adj 阈值	|log2FC| 阈值	特征数	显著数	上调	下调	P_adj 缺失	全部核对
0.01	0	14599	731	328	403	5800	pass
0.01	1	14599	181	89	92	5800	pass
0.05	0	14599	1068	481	587	5800	pass
0.05	1	14599	218	108	110	5800	pass
0.10	0	14599	1330	613	717	5800	pass
0.10	1	14599	244	125	119	5800	pass

表注： pasilla 1.30.0 归档包含 14,599 个特征和 7 个文库；DESeq2 设计为 ~ type + condition，比较 treated vs untreated。每一行将 BioExplainR 从真实 DESeqResults 提取的事实与直接源表计算结果逐项比较；6 个阈值组合、每组合 5 个事实，共 30/30 匹配。P_{adj} 缺失值来自保存的 DESeq2 结果，不等于没有原始检验。

来源： research/results/related_tools/pasilla_fact_checks.csv；pasilla_test.json；pasilla_1.30.0.tar.gz 的 SHA-256

补充表 S4. 双模型规模共同任务结果

方法	输入/协议	目标事实	正确	已回答	匹配率	覆盖率	备注
StepFun step-5-preview	OpenAI-compatible; response_format disabled	480	480	480	100.0%	100.0%	120 个案例、480 个目标事实；完整小数提示修复后评分
DeepSeek deepseek-flash	OpenAI-compatible; response_format disabled	480	480	480	100.0%	100.0%	120 个案例、480 个目标事实；完整小数提示修复后评分

表注： 两个在线模型各处理 120 个可复现案例、480 个预定义标量事实，各运行一次；输入包含 R 计算事实，因此这是结构化事实传递和协议适配的机制性比较，不是泛化性能排名。正确/目标为严格 fact-path 与数值匹配；已回答为非空标量声明；覆盖率为已回答/目标。StepFun 与 DeepSeek 均为 480/480，提示要求保留完整小数精度。StepFun 使用关闭 response_format=json_object 的 OpenAI-compatible 请求。

来源： research/results/common_task_scale_480/common_task_summary.csv；common_task_calls.csv；common_task_manifest.json；脱敏响应记录

补充表 S5. 外部评分者与功能感知评价

部分	对象/维度	n	均值	标准差	有用/一致比例	说明
外部评分者	biological_support	90	1.733	0.445		允许 0-2 分；3 位外部评分者；30 个匿名案例；本批无 0 分记录
外部评分者	error_localization	90	1.933	0.251		允许 0-2 分；3 位外部评分者；30 个匿名案例；本批无 0 分记录
外部评分者	numeric_accuracy	90	1.756	0.432		允许 0-2 分；3 位外部评分者；30 个匿名案例；本批无 0 分记录
外部评分者	readability	90	1.956	0.207		允许 0-2 分；3 位外部评分者；30 个匿名案例；本批无 0 分记录
外部评分者	semantic_preservation	90	1.722	0.450		允许 0-2 分；3 位外部评分者；30 个匿名案例；本批无 0 分记录
外部评分者	statistical_concepts	90	1.689	0.466		允许 0-2 分；3 位外部评分者；30 个匿名案例；本批无 0 分记录
外部评分者	traceability	90	1.267	0.445		允许 0-2 分；3 位外部评分者；30 个匿名案例；本批无 0 分记录

部分	对象/维度	n	均值	标准差	有用/一致比例	说明
外部评分者	uncertainty	90	1.956	0.207		允许 0-2 分；3 位外部评分者；30 个匿名案例；本批无 0 分记录
外部评分者	overall	720	1.751	0.433	93.8%	允许 0-2 分；3 位外部评分者；30 个匿名案例；本批无 0 分记录
功能感知	运行并记录 R 代码	30	91.57	4.88	100.0%	0-100 功能感知评分；1=有用，2=没用
功能感知	解释 R 生物信息学对象	30	91.00	5.87	93.3%	0-100 功能感知评分；1=有用，2=没用
功能感知	生成常用分析图形	30	93.03	4.47	100.0%	0-100 功能感知评分；1=有用，2=没用
功能感知	证据与来源追踪	30	91.23	7.78	90.0%	0-100 功能感知评分；1=有用，2=没用
功能感知	生成分析报告	30	93.07	4.71	96.7%	0-100 功能感知评分；1=有用，2=没用
功能感知	全部功能	150	91.98	5.67	96.0%	0-100 功能感知评分；1=有用，2=没用

表注： 3 位外部评分者对 30 个去来源化解释案例、8 个维度进行 0-2 评分，共 720 条，无缺失；均值为评分者×案例的描述性汇总，case-dimension 完全一致率为 93.75%，相差不超过 1 分的比例为 100%。30 位评分参与者对 5 项功能进行 0-100 功能感知评分和 1=有用/2=没用判断，共 150 条，无缺失；这些是描述性功能感知结果，不是 SUS、学习增益、临床效用或随机对照实验。

来源： research/results/human_evaluation/expert_dimension_summary.csv；user_feature_summary.csv；expert_agreement_summary.csv；human_evaluation_manifest.json

补充材料索引。 独立文件 `BioExplainR-supplementary.docx` 包含 S1 数据/版本与复现、S2 相近工具和 pasilla、S3 消融与原始记录、S3b 双模型与代码代理共同任务、S4 预实验迭代、S5 外部评分者与功能感知评价、S6 数值通过的语义负例、S7 机制挑战与浏览器记录、S8 投稿信息缺口。`supplementary_records.zip` 保留原始提示/响应、CSV、清单和截图，提供逐文件 SHA-256 清单；大型原始数据缓存不嵌入 Word。附件图表文件与索引见 `submission_assets/README.md`。